

UNIVERSIDAD DE OVIEDO



Universidad de Oviedo



Escuela de
Ingeniería
Informática

ESCUELA DE INGENIERÍA INFORMÁTICA

TRABAJO FIN DE GRADO

**“ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS
CLAVE EN TEXTOS EDUCATIVOS”**

AUTOR: Jorge López Peláez

TUTOR: Jordán Pascual Espada

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	--

AGRADECIMIENTOS

Hace cuatro años ya que comencé el grado y son numerosos los momentos vividos, tanto buenos como malos, es por ello que el apoyo de compañeros y familia ha sido fundamental para poder decir hoy que he disfrutado el camino.

En primer lugar, tengo que agradecer a mis padres y a mi hermano, mi familia más cercana y con la que paso la mayoría del tiempo, han estado aguantándome durante estos años y sobre todo apoyándome, pero si tengo que destacar a alguien, es a mi madre, que ha sido capaz de ayudarme en las malas, así como de celebrar conmigo los pequeños buenos momentos.

De igual manera, todos los amigos que he hecho en la universidad han resultado ser un gran apoyo. Con ellos he conseguido mejorar en muchos aspectos, uno de ellos el académico ya que siempre ofrecían su punto de vista, permitiendo siempre encontrar soluciones a los problemas que nos hemos ido encontrando a lo largo del camino.

Finalmente, todo el conocimiento que he adquirido en estos años ha sido gracias a los profesores, agradecerles el esfuerzo y dedicación. Han sido muchos los profesores que he tenido durante toda la carrera y todos han conseguido impartir su conocimiento, es por ellos que hoy estoy aquí.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO
			JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es

CONTROL DE VERSIONES

Versión	Fecha	Descripción
1.0.0	20/10/2023	Versión inicial del trabajo de fin de grado

ÍNDICE DE CONTENIDO

1	ACERCA DEL TRABAJO.....	13
1.1	RESUMEN	13
1.2	MOTIVACIÓN	13
1.3	PALABRAS CLAVE.....	14
2	ESTUDIO DEL ALGORITMO	15
2.1	CONTEXTO EN QUE SE ENMARCA LA EXTRACCIÓN DE KEYWORDS	15
2.1.1	<i>Opciones para realizar la extracción de keywords.....</i>	<i>15</i>
2.2	ALGORITMO DESARROLLADO BASADO EN TF-IDF	18
2.2.1	<i>¿Qué es TF-IDF y de dónde viene?.....</i>	<i>19</i>
2.2.2	<i>Proceso de TF.....</i>	<i>20</i>
2.2.3	<i>Proceso de IDF.....</i>	<i>21</i>
2.2.4	<i>Cálculo del puntaje.....</i>	<i>22</i>
2.3	ANÁLISIS DE RESULTADOS.....	23
2.3.1	<i>True Positive.....</i>	<i>23</i>
2.3.2	<i>False Positive</i>	<i>24</i>
2.3.3	<i>True Negative</i>	<i>24</i>
2.3.4	<i>False Negative</i>	<i>24</i>
2.3.5	<i>Precisión (Precision).....</i>	<i>24</i>
2.3.6	<i>Exhaustividad (Recall)</i>	<i>24</i>
2.3.7	<i>F1 Score.....</i>	<i>25</i>
2.3.8	<i>Dataset.....</i>	<i>25</i>
2.3.9	<i>Análisis de resultados.....</i>	<i>28</i>
2.3.10	<i>Conclusiones del estudio de algoritmos</i>	<i>37</i>
2.3.11	<i>Algoritmo personalizado en profundidad.....</i>	<i>38</i>
2.3.12	<i>Discusión de resultados.....</i>	<i>42</i>
3	ESTUDIO DE VIABILIDAD DEL SISTEMA.....	47
3.1	ANÁLISIS DE SISTEMAS SIMILARES	47
3.1.1	<i>OpenAI GPT-3.....</i>	<i>47</i>
3.1.2	<i>BERT (Bidirectional Encoder Representations from Transformers) (Google).....</i>	<i>47</i>

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

3.1.3	<i>T5 (Text-to-Text Transfer Transformer)</i>	48
3.1.4	<i>Quillionz</i>	48
3.1.5	<i>Semantha</i>	49
3.2	VALORACIÓN DE ALTERNATIVAS DE SOLUCIÓN	49
3.2.1	<i>Alternativas de enfoque del algoritmo</i>	50
3.2.2	<i>Desarrollo del back-end de la aplicación</i>	50
3.2.3	<i>Desarrollo del front-end de la aplicación web</i>	54
4	PLANIFICACIÓN Y GESTIÓN DEL PROYECTO	57
4.1	PLANIFICACIÓN	57
4.2	RIESGOS	60
4.2.1	<i>Plan de gestión de riesgos</i>	60
4.2.2	<i>Valoración de riesgos</i>	60
4.2.3	<i>Gestión de riesgos</i>	63
4.3	PRESUPUESTO	64
4.3.1	<i>Gastos de personal</i>	64
4.3.2	<i>Material y licencias</i>	64
4.3.3	<i>Total de los costes</i>	65
5	ANÁLISIS DEL SISTEMA DE INFORMACIÓN	66
5.1	DETERMINACIÓN DEL ALCANCE DEL SISTEMA	66
5.2	IDENTIFICACIÓN DE ACTORES DEL SISTEMA	66
5.3	ESTABLECIMIENTO DE REQUISITOS	66
5.3.1	<i>Obtención de los Requisitos del Sistema</i>	66
5.4	ESPECIFICACIÓN DE CASOS DE USO Y ESCENARIOS	72
5.4.1	<i>Diagrama de contexto</i>	72
5.4.2	<i>Especificación de casos de uso</i>	73
5.5	IDENTIFICACIÓN DE SUBSISTEMAS A NIVEL DE ARQUITECTURA DE LA APLICACIÓN	83
5.5.1	<i>Descripción de los subsistemas a nivel de arquitectura</i>	84
5.6	DEFINICIÓN DE INTERFACES DE USUARIO	84
5.6.1	<i>Pantalla de inicio</i>	84
5.6.2	<i>Pantalla de inicio de sesión</i>	85
5.6.3	<i>Pantalla de registro de usuario</i>	86

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

5.6.4	<i>Pantalla de carga del texto.....</i>	87
5.6.5	<i>Pantalla de palabras clave.....</i>	88
5.6.6	<i>Pantalla de gestión de preguntas.....</i>	89
5.6.7	<i>Pantalla de búsqueda de exámenes.....</i>	90
5.6.8	<i>Pantalla de resolución de examen.....</i>	91
5.6.9	<i>Diagrama de navegabilidad.....</i>	91
6	DISEÑO DEL SISTEMA DE INFORMACIÓN.....	93
6.1	DISEÑO FÍSICO DE DATOS.....	93
6.1.1	<i>Descripción del SGBD utilizado.....</i>	93
6.1.2	<i>Integración del SGBD en el sistema.....</i>	93
6.2	DISEÑO DE LA API REST.....	93
6.2.1	<i>Procesamiento del texto.....</i>	93
6.2.2	<i>Keywords.....</i>	94
6.2.3	<i>Preguntas.....</i>	94
6.2.4	<i>Usuarios.....</i>	94
6.2.5	<i>Exámenes.....</i>	96
6.3	DIAGRAMA DE DESPLIEGUE.....	97
6.4	DISEÑO DEL PLAN DE PRUEBAS.....	97
6.4.1	<i>Pruebas de la Restapi.....</i>	97
7	IMPLEMENTACIÓN DEL SISTEMA DE INFORMACIÓN.....	100
7.1	LENGUAJES DE PROGRAMACIÓN.....	100
7.1.1	<i>JavaScript.....</i>	100
7.2	HERRAMIENTAS USADAS PARA EL DESARROLLO.....	100
7.2.1	<i>Visual Studio Code.....</i>	100
7.2.2	<i>Mozilla Firefox.....</i>	100
7.2.3	<i>Git.....</i>	101
8	EJECUCIÓN DE LAS PRUEBAS.....	102
8.1	PRUEBAS DE LA RESTAPI.....	102
9	MANUALES DE USUARIO.....	104
9.1	MANUAL PARA EL DESARROLLADOR.....	104
9.1.1	<i>Descargar el código de la Webapp.....</i>	104

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	---	---	--

9.1.2	<i>Descargar el código de la Restapi</i>	104
9.1.3	<i>Instalación de la Restapi</i>	105
9.1.4	<i>Instalación de la Webapp</i>	107
9.2	MANUAL DE USUARIO	107
9.2.1	<i>Acceso al sistema</i>	107
9.2.2	<i>Autenticación de usuario</i>	108
9.2.3	<i>Procesamiento de textos</i>	109
9.2.4	<i>Gestión de palabras clave</i>	110
9.2.5	<i>Gestión de preguntas</i>	112
9.2.6	<i>Búsqueda de exámenes</i>	115
9.2.7	<i>Realización de examen</i>	116
10	CONCLUSIONES Y AMPLIACIONES	118
10.1	CONCLUSIONES	118
10.2	LÍNEAS FUTURAS	118
10.2.1	<i>Líneas futuras relacionadas con la mejora del algoritmo</i>	118
10.2.2	<i>Líneas futuras relacionadas con la mejora de la aplicación web y la obtención de preguntas</i>	123
11	REFERENCIAS BIBLIOGRÁFICAS	127
12	GLOSARIO	129
13	ANEXOS	131
13.1	PLAN DE GESTIÓN DE RIESGOS	131
13.1.1	<i>Valoración de riesgos</i>	132
13.1.2	<i>Gestión de riesgos</i>	133
13.2	CONTENIDO DE LOS ANEXOS ENTREGADOS	133

ÍNDICE DE FIGURAS

Ilustración 2-1: Fórmula del cálculo del puntaje de TF-IDF	19
Ilustración 2-2: Fórmula del cálculo de TF (TF-IDF)	21
Ilustración 2-3: Fórmula del cálculo de IDF (TF-IDF)	22
Ilustración 2-4: Fórmula final del cálculo de TF-IDF	23
Ilustración 2-5: TP, TN, FP, FN visto gráficamente. Imagen sacada de Wikipedia.	25
Ilustración 2-6: Precisión y Exhaustividad visto gráficamente. Imagen sacada de Wikipedia.	25
Ilustración 4-1: Planificación inicial del proyecto mostrado en un documento Project.	58
Ilustración 4-2: Planificación final del proyecto mostrado en un documento Project....	58
Ilustración 5-1: Diagrama de contexto de la aplicación	73
Ilustración 5-2: Diagrama de casos de uso de procesamiento de texto	75
Ilustración 5-3: Diagrama de casos de uso de gestión de palabras clave	77
Ilustración 5-4: Diagrama de casos de uso de gestión de preguntas	79
Ilustración 5-5: Diagrama de casos de uso de búsqueda y realización de exámenes	82
Ilustración 5-6: Subsistemas de arquitectura simplificado	84
Ilustración 5-7: Boceto de la pantalla de inicio	85
Ilustración 5-8: Boceto de la pantalla de inicio de sesión	86
Ilustración 5-9: Boceto de la pantalla de registro de sesión	87
Ilustración 5-10: Boceto de la pantalla de carga del texto.....	88
Ilustración 5-11: Boceto de la pantalla de gestión de palabras clave	89
Ilustración 5-12: Boceto de la pantalla de gestión de preguntas	90
Ilustración 5-13: Boceto de la pantalla de búsqueda de exámenes.....	90
Ilustración 5-14: Boceto de la pantalla de resolución de examen	91
Ilustración 5-15: Diagrama de navegabilidad del sistema.....	92
Ilustración 6-6-1: Diagrama de despliegue del sistema.....	97
Ilustración 8-1: Ejecución de las pruebas de la Restapi	102
Ilustración 9-1: Descarga del fichero comprimido de la Webapp de GitHub	104
Ilustración 9-2: Descarga del fichero comprimido de la Restapi de GitHub.....	105
Ilustración 9-3: Descarga de la última versión LTS de Node.js.....	106

Ilustración 9-4: Acceso a registro e inicio de sesión	108
Ilustración 9-5: Formulario de inicio de sesión	108
Ilustración 9-6: Formulario de registro.....	109
Ilustración 9-7: Procesamiento de texto	110
Ilustración 9-8: Vista de las palabras clave extraídas del texto	110
Ilustración 9-9: Campo para añadir una nueva palabra clave.....	111
Ilustración 9-10: Nueva palabra clave añadida al listado	111
Ilustración 9-11: Selección de varias palabras un número determinado de veces.....	111
Ilustración 9-12: Preguntas generadas por el sistema.....	112
Ilustración 9-13: Editando el enunciado de una pregunta	112
Ilustración 9-14: Editando las opciones de una pregunta	113
Ilustración 9-15: Borrado de una pregunta	113
Ilustración 9-16: Guardando examen en base de datos	113
Ilustración 9-17: Diálogo para insertar la id pública del examen a guardar en base de datos	114
Ilustración 9-18: Generación de link para descarga de examen	114
Ilustración 9-19: Link para descarga de examen	114
Ilustración 9-20: Descarga del archivo de texto con el examen en formato Aiken.....	114
Ilustración 9-21: Fichero descargado con el examen en formato Aiken	115
Ilustración 9-22: Búsqueda de un examen por su id pública.....	115
Ilustración 9-23: Búsqueda de examen con id concreta, examenDePrueba	115
Ilustración 9-24: Vista de examen concreto con id examenDePrueba	116
Ilustración 9-25: Selección de opciones en la respuesta a un examen	116
Ilustración 9-26: Botón de corregir examen	116
Ilustración 9-27: Pregunta acertada	117
Ilustración 9-28: Pregunta fallada.....	117
Ilustración 9-29: Pregunta en blanco	117
Ilustración 10-1: Lógica borrosa aplicada gráficamente	121
Ilustración 10-2: Ejemplo de cómo trabaja TensorFlow	123
Ilustración 13-1: Plan de gestión de riesgos	131

ÍNDICE DE TABLAS

Tabla 1: Número de palabras y keywords de los textos de ' <i>US History</i> '	26
Tabla 2: Número de palabras y keywords de los textos de ' <i>The American Peageant</i> ' ...	27
Tabla 3: Número de palabras y keywords de los textos de ' <i>Modern World History - Cambridge</i> '	28
Tabla 4: Número de palabras y keywords de los textos de ' <i>From Yesterday To Tomorrow</i> '	28
Tabla 5: Datos recogidos aplicando TextRank a los tres primeros textos de cada conjunto	30
Tabla 6: Medias de los datos recogidos para TextRank sobre los tres primeros textos de cada conjunto.....	30
Tabla 7: Datos recogidos aplicando TF-IDF básico a los tres primeros textos de cada conjunto	32
Tabla 8: Medias de los datos recogidos para TF-IDF básico sobre los tres primeros textos de cada conjunto	32
Tabla 9: Datos recogidos aplicando RAKE a los tres primeros textos de cada conjunto	34
Tabla 10: Medias de los datos recogidos para RAKE sobre los tres primeros textos de cada conjunto.....	34
Tabla 11: Datos recogidos aplicando TF-IDF modificado a los tres primeros textos de cada conjunto.....	36
Tabla 12: Medias de los datos recogidos para TF-IDF modificado sobre los tres primeros textos de cada conjunto.....	36
Tabla 13: Medias de F1 Score comparando algoritmos según el conjunto de textos.....	38
Tabla 14: Aplicación del algoritmo modificado para los 15 primeros textos de ' <i>The American Peageant</i> '	39
Tabla 15: Medias para el algoritmo modificado de los 15 primeros textos de ' <i>The American Peageant</i> '	39
Tabla 16: Aplicación del algoritmo modificado para los 15 primeros textos de ' <i>US History</i> '	40
Tabla 17: Medias para el algoritmo modificado de los 15 primeros textos de ' <i>US History</i> '	40
Tabla 18: Aplicación del algoritmo modificado para los 10 textos de ' <i>Modern World History - Cambridge</i> '	40
Tabla 19: Medias para el algoritmo modificado de los 10 textos de ' <i>Modern World History - Cambridge</i> '	41

Tabla 20: Aplicación del algoritmo modificado para los 6 textos de ' <i>From Yesterday To Tomorrow</i> '	41
Tabla 21: Medias para el algoritmo modificado de los 6 textos de ' <i>From Yesterday To Tomorrow</i> '	41
Tabla 22: Resumen de los datos para el algoritmo modificado mostrando medias de TP, FN, FP, Precision, Recall y F1 Score	42
Tabla 23: Medias de los TP obtenidos para el algoritmo modificado con cada uno de los conjuntos de textos	43
Tabla 24: Medias de los FP obtenidos para el algoritmo modificado con cada uno de los conjuntos de textos	43
Tabla 25: Medias de los FN obtenidos para el algoritmo modificado con cada uno de los conjuntos de textos	44
Tabla 26: Medias de la Precision obtenida para el algoritmo modificado con cada uno de los conjuntos de textos.....	44
Tabla 27: Medias de la Recall obtenida para el algoritmo modificado con cada uno de los conjuntos de textos	45
Tabla 28: Medias de los F1 Score obtenidos para el algoritmo modificado con cada uno de los conjuntos de textos.....	45
Tabla 29: Comparativa de tecnologías a aplicar en el back-end de la aplicación	53
Tabla 30: Comparativa de tecnologías a aplicar en el front-end de la aplicación	56
Tabla 31: Descripción de las fases de planificación del proyecto	58
Tabla 32: Desglose de días por tarea de la planificación	59
Tabla 33: Riesgos identificados.....	61
Tabla 34: Probabilidad e impacto tras análisis de riesgos	61
Tabla 35: Matriz de impacto y probabilidad	62
Tabla 36: Riesgos priorizados por su impacto calculado	62
Tabla 37: Descripción del presupuesto: Gastos en personal	64
Tabla 38: Descripción del presupuesto: Gastos en material y licencias.....	64
Tabla 39: Descripción del presupuesto: Costes finales	65
Tabla 40: Caso de uso de ver la página principal	73
Tabla 41: Caso de uso de registro de usuarios.....	74
Tabla 42: Caso de uso de inicio de sesión de usuarios.....	74
Tabla 43: Caso de uso de salir de sesión de usuarios	75
Tabla 44: Caso de uso de introducir texto en área para procesamiento	76

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	--

Tabla 45: Caso de uso de subir archivo de texto para procesamiento	76
Tabla 46: Caso de uso de cargar texto de prueba para procesamiento	77
Tabla 47: Caso de uso de ver las palabras clave.....	77
Tabla 48: Caso de uso de seleccionar todas las palabras clave	78
Tabla 49: Caso de uso de deseleccionar todas las palabras clave	78
Tabla 50: Caso de uso de añadir una palabra clave	79
Tabla 51: Caso de uso de modificar el número de preguntas por palabra clave	79
Tabla 52: Caso de uso de vista de preguntas	80
Tabla 53: Caso de uso de generación de preguntas por palabra clave	80
Tabla 54: Caso de uso de edición del enunciado de las preguntas	81
Tabla 55: Caso de uso de edición de las opciones de las preguntas.....	81
Tabla 56: Caso de uso de eliminación de preguntas.....	81
Tabla 57: Caso de uso de exportación de preguntas.....	82
Tabla 58: Caso de uso de guardado de preguntas.....	82
Tabla 59: Caso de uso de búsqueda de exámenes	83
Tabla 60: Caso de uso de realización de exámenes.....	83

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

1 Acerca del trabajo

1.1 Resumen

Los algoritmos de extracción de palabras clave consisten en la identificación de palabras marcadas como importantes dentro de un texto con una temática determinada. Cabe destacar que el objetivo de las palabras clave en este proyecto es generar preguntas de tipo test que sirvan de repaso, ya que, en otras circunstancias, como puede ser querer resumir un texto o clasificarlo, las palabras que se buscarán serán totalmente diferentes, buscando en el caso de un resumen las palabras que más se repitan, por ejemplo. En el caso de este proyecto, lo que se buscan son palabras representativas del texto, cuyo significado sea importante en el mismo.

La extracción de palabras clave se puede realizar mediante técnicas de inteligencia artificial o, como es el caso de este proyecto, mediante algoritmos supervisados, concretamente, el enfoque estadístico.

En concreto TF-IDF, frecuencia de término – frecuencia inversa de documento, es una medida numérica que expresa cómo de relevante es una palabra para un documento. Por otro lado, POS es un procesamiento de texto basado en el etiquetado gramatical, es decir, sirve para clasificar gramaticalmente las palabras, lo que permite tratar de distinta manera a dichas palabras según su categoría gramatical.

Este proyecto tiene como objetivo permitir a los profesores generar preguntas de tipo test sobre su temario, especialmente en la temática de historia, esto es importante ya que un mismo algoritmo es difícil que resulte útil para diferentes temáticas, en textos de historia, las palabras clave serán en numerosas ocasiones las palabras que comiencen en mayúscula (nombres propios, lugares, batallas...), sin embargo, en otros textos como pueden ser de química, es más probable que destaquen fórmulas, por ejemplo.

Mediante un algoritmo de búsqueda de palabras clave se obtendrán las mismas del texto de historia, pudiendo así elegir qué palabras clave son las que queremos que se utilicen para generar las preguntas de tipo test. Finalmente, se generarán las preguntas, las cuales se formulan como la propia frase de la palabra, con un espacio en blanco donde ésta debería ir y como opciones palabras de la misma categoría gramatical, además de la propia palabra que es la respuesta correcta.

1.2 Motivación

La realización de preguntas de tipo test son útiles para kahoots, juegos, ejercicios de repaso, etc. Es por ello que este trabajo está orientado a generar preguntas del tipo mencionado en grandes volúmenes para facilitar dichos procesos. Además, se busca generar una gran cantidad de preguntas para alimentar juegos educativos que los profesores utilizarán en sus clases con sus alumnos.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO
			JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es

El objetivo final de las preguntas es alimentar dichos juegos que serán utilizados por los profesores en sus clases, aportando grandes volúmenes de preguntas, que, sin ser de una gran dificultad, permitan adquirir determinados conocimientos sobre la materia y repasar el temario. Estos juegos están siendo desarrollados en otra investigación y se basan en avanzar en el juego a medida que aciertas preguntas.

Otro aspecto a destacar en la motivación es la falta de acierto y eficacia de los algoritmos actuales de extracción de palabras clave aplicados al ámbito de la educación, es por ello que en este proyecto se va a modificar uno de ellos para intentar mejorar su efectividad.

1.3 Palabras clave

Keyword, TF-IDF, POS, Procesamiento de textos, Node JS, React, JavaScript, Render, GitHub, GitHub Pages.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

2 Estudio del algoritmo

2.1 Contexto en que se enmarca la extracción de keywords

Los algoritmos de extracción de palabras clave sirven para obtener, a partir de un texto, una serie de ‘keywords’ (palabras clave) que representen las palabras del propio documento. Dichas palabras suelen ser las consideradas más importantes del texto, sin embargo, el término ‘más importante’ es relativo y depende del contexto en el que quieran utilizarse las mismas (clasificar un documento, resumirlo, compararlo, sacar preguntas de él...).

Dependiendo del algoritmo pueden guiarse por distintos caminos, algunos asignando valores a la importancia de las palabras, otros formando grafos.

2.1.1 Opciones para realizar la extracción de keywords

A continuación, se muestran algunas de las alternativas que dan solución a la búsqueda y extracción de palabras clave:

2.1.1.1 Análisis gramatical

Dicho análisis se refiere al examen de la estructura gramatical de un texto con el fin de identificar y seleccionar palabras en función de su categoría, en el caso aplicado de la extracción de palabras clave dichas palabras serán las más relevantes o significativas dependiendo del objetivo de la extracción. El proceso implica analizar la función y la relación de las palabras en una oración o fragmento de texto para determinar cuáles son las más relevantes en términos de contenido.

El proceso incluye la identificación de partes del discurso, frases nominales, excluyendo palabras vacías, analizando modificadores y conectores.

2.1.1.2 Enfoque basado en frecuencia

Este enfoque identifica las palabras clave basándose en la frecuencia de aparición en un texto o conjunto de textos. Las palabras más frecuentes suelen considerarse palabras clave. Sin embargo, este método no tiene en cuenta el contexto o la relevancia semántica de las palabras.

Un ejemplo de un algoritmo basado en frecuencia en el contexto de la búsqueda de palabras clave es el algoritmo TF-IDF (Term Frequency-Inverse Document Frequency). Este algoritmo se utiliza comúnmente en motores de búsqueda y sistemas de recuperación de información para evaluar la importancia de una palabra clave en un conjunto de documentos o texto. Este algoritmo permite identificar palabras clave que son importantes

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

en un contexto específico, ya que da más peso a las palabras clave que son frecuentes en un documento, pero raras en el conjunto de documentos. Estos puntajes TF-IDF se pueden utilizar para clasificar la importancia de las palabras clave en el contexto de la búsqueda de información o para la optimización de contenido en SEO.

2.1.1.3 Enfoque basado en heurísticas

Estos algoritmos utilizan reglas específicas y heurísticas para extraer palabras clave. Estas reglas pueden basarse en la posición de las palabras en el texto, en su estructura gramatical o en otros patrones lingüísticos. Por ejemplo, se pueden considerar como palabras clave los sustantivos propios o los verbos en infinitivo.

Un enfoque basado en heurísticas es útil cuando tienes un conocimiento específico de tu nicho o industria y deseas aplicar criterios personalizados para la selección de palabras clave. Puede ser especialmente efectivo para proyectos pequeños o nichos de mercado específicos donde las herramientas de análisis de palabras clave pueden no ser tan precisas o relevantes. Sin embargo, es importante recordar que las reglas heurísticas deben basarse en una comprensión sólida de las necesidades y expectativas de tu público objetivo.

2.1.1.4 Algoritmos supervisados

Estos algoritmos se entrenan utilizando conjuntos de datos etiquetados, donde las palabras clave están previamente anotadas. Utilizan técnicas de aprendizaje automático, como clasificación o regresión, para predecir las palabras clave en nuevos textos. Estos algoritmos pueden basarse en características lingüísticas, estadísticas o semánticas de las palabras y su contexto. Un ejemplo de un algoritmo supervisado en la búsqueda de palabras clave podría implicar el uso de un clasificador de texto entrenado para etiquetar automáticamente palabras clave en función de un conjunto de datos de entrenamiento.

Un enfoque supervisado puede ser especialmente útil cuando tienes acceso a un conjunto de datos de entrenamiento grande y etiquetado. El algoritmo supervisado aprenderá de los ejemplos proporcionados en el conjunto de entrenamiento y, con el tiempo, puede mejorar su precisión en la clasificación de palabras clave.

Este enfoque es aplicable en situaciones en las que se necesita automatizar la asignación de palabras clave o etiquetas en contenido textual, como la categorización de productos en un catálogo en línea, la organización de noticias, la clasificación de correos electrónicos, entre otros.

2.1.1.5 Enfoque basado en grafos de palabras

Este enfoque construye un grafo de palabras a partir del texto, donde cada palabra se representa como un nodo y las relaciones entre palabras se representan como aristas.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

Luego, se utilizan algoritmos de análisis de grafos para identificar las palabras clave más importantes. Estos algoritmos tienen en cuenta el contexto y la coocurrencia de palabras.

Un ejemplo de un algoritmo basado en grafos de palabras es el algoritmo TextRank, que se utiliza comúnmente para la extracción de palabras clave y el resumen automático de texto. TextRank es una variante de PageRank, el algoritmo utilizado por Google para clasificar páginas web en los resultados de búsqueda. TextRank se basa en la estructura de un grafo de palabras para determinar la importancia de las palabras clave en un documento de texto.

Este enfoque es útil para identificar palabras clave en un texto, especialmente cuando se trata de resúmenes automáticos, etiquetado de contenido y otras aplicaciones donde se necesita una comprensión profunda de la estructura y el significado del texto.

2.1.1.6 Algoritmos basados en modelos de lenguaje

Estos algoritmos utilizan modelos de lenguaje entrenados previamente, como los modelos de transformer, para predecir la probabilidad de que una palabra sea una palabra clave dada su aparición en un contexto determinado. Estos modelos tienen en cuenta la semántica y el contexto de las palabras, lo que puede mejorar la precisión de la extracción de palabras clave.

Un ejemplo de un algoritmo basado en modelos de lenguaje para la búsqueda de palabras clave sería la utilización de modelos de lenguaje pre-entrenados, como BERT (Bidirectional Encoder Representations from Transformers), GPT (Generative Pre-trained Transformer) u otros modelos similares. Estos modelos pueden ayudar a identificar palabras clave y frases relevantes en un documento de manera más precisa al comprender el contexto y la semántica del lenguaje.

Este enfoque basado en modelos de lenguaje es particularmente efectivo para comprender el significado de las palabras clave en un contexto más amplio, lo que permite una identificación más precisa de las palabras clave relevantes. Además de BERT, otros modelos de lenguaje, como RoBERTa, XLNet y T5, también se pueden utilizar de manera similar para la búsqueda de palabras clave y tareas de procesamiento del lenguaje natural.

2.1.1.7 Algoritmos basados en modelos estadísticos

Los algoritmos basados en modelos estadísticos son enfoques que se centran en el uso de estadísticas y datos para abordar una variedad de tareas, desde el procesamiento de lenguaje natural hasta la clasificación de información y la toma de decisiones. Estos algoritmos utilizan datos observacionales y técnicas estadísticas para generar resultados, en lugar de depender de reglas predefinidas o lógica estricta. Algunos ejemplos son:

- **Regresión Lineal:** La regresión lineal es un algoritmo estadístico utilizado para modelar la relación entre una variable dependiente y una o más variables

independientes. Se utiliza para predecir valores numéricos y se basa en la minimización de la suma de los errores cuadrados.

- Regresión Logística: Aunque el nombre sugiere "regresión", la regresión logística se utiliza para problemas de clasificación binaria o multiclase. Se basa en la función logística para modelar la probabilidad de que un evento ocurra.

YAKE (Yet Another Keyword Extractor) es un algoritmo de extracción de palabras clave que se enmarca en esta categoría de algoritmos. YAKE utiliza una combinación de técnicas de procesamiento de lenguaje natural y algoritmos estadísticos para identificar palabras clave en un texto de manera automática. En particular, YAKE se basa en el análisis de frecuencias, la detección de candidatos a palabras clave, y el cálculo de puntajes de importancia para determinar las palabras clave más relevantes en un documento. Este enfoque se encuentra dentro de la categoría de algoritmos de extracción de palabras clave que no dependen de modelos de lenguaje pre-entrenados o conocimiento contextual, como BERT o GPT, sino que se centran en la frecuencia y la relevancia de las palabras dentro del texto. YAKE se utiliza comúnmente en tareas de extracción de palabras clave automáticas, etiquetado de contenido y resumen automático, y es una opción útil para identificar palabras clave en documentos o textos sin requerir el entrenamiento específico de un modelo de lenguaje.

Los algoritmos basados en modelos estadísticos son fundamentales en muchas disciplinas, desde la estadística hasta el aprendizaje automático y la inteligencia artificial. Estos algoritmos se utilizan para modelar datos, tomar decisiones basadas en datos y obtener conocimientos a partir de observaciones. La elección del algoritmo adecuado depende de la tarea específica y la naturaleza de los datos.

2.2 Algoritmo desarrollado basado en TF-IDF

A pesar de ser muchas y muy variadas las alternativas para obtener una solución al problema de extraer palabras clave de un texto, en este trabajo se ha optado por el estudio e implementación de un algoritmo basado en estadísticas. Concretamente, basado en frecuencia, analizando la importancia relativa de una palabra en un documento o conjunto de documentos.

La decisión final de optar por este algoritmo fue consensuada con el tutor del proyecto, ya que se realizaron otros trabajos de fin de grado similares aplicando otros algoritmos y la idea era buscar otro distinto que pudiese obtener diferentes resultados.

En la estructura del algoritmo se pueden diferenciar fácilmente tres etapas:

1. **Frecuencia de Término (TF):** En esta etapa, se calcula la Frecuencia de Término, que mide la importancia de una palabra clave en un documento específico en función de cuántas veces aparece la palabra clave en ese documento. La idea es que cuanto más a menudo aparece una palabra clave en un documento, más relevante es esa palabra clave para ese documento. En esta etapa, se obtiene un puntaje TF para cada palabra clave en un documento específico.

2. **Frecuencia Inversa de Documento (IDF):** La etapa de Frecuencia Inversa de Documento (IDF) evalúa la importancia de una palabra clave en un conjunto de documentos más amplio, teniendo en cuenta cuántos documentos contienen la palabra clave. La idea es que las palabras clave que aparecen en pocos documentos pero que son relevantes en esos pocos documentos tienen un mayor valor. En esta etapa, se obtiene un puntaje IDF para cada palabra clave basado en su frecuencia de aparición en el conjunto de documentos. La función logarítmica se utiliza para suavizar los puntajes IDF.
3. **Cálculo del puntaje TF-IDF:** Finalmente, el puntaje TF-IDF para una palabra clave 't' en un documento 'd' se calcula multiplicando el puntaje TF (obtenido en la etapa 1) por el puntaje IDF (obtenido en la etapa 2). El puntaje TF-IDF resultante refleja la importancia relativa de la palabra clave en el contexto del documento y el conjunto de documentos. Las palabras clave con puntajes TF-IDF más altos son consideradas más relevantes para el contenido específico del documento.

$$\underbrace{\text{TF-IDF}}_{(n,d)} = \underbrace{\text{TF}}_{(n,d)} \times \underbrace{\text{IDF}}_{(n)}$$

Peso de un término (n) en un documento (d)

Frecuencia de aparición de un término (n) en un documento (d)

Factor IDF de un término (n)

Ilustración 2-1: Fórmula del cálculo del puntaje de TF-IDF

2.2.1 ¿Qué es TF-IDF y de dónde viene?

TF-IDF, que significa "Term Frequency-Inverse Document Frequency" en inglés, es una técnica utilizada en el procesamiento de lenguaje natural (NLP) y la recuperación de información para evaluar la importancia relativa de una palabra clave en un documento o conjunto de documentos. Esta técnica se utiliza comúnmente para la búsqueda de información, la clasificación de texto y la extracción de palabras clave.

Como se comentó en el apartado anterior, TF-IDF consta de dos etapas principales (más una tercera para el cálculo del puntaje final):

1. **Frecuencia de Término (TF - Term Frequency):** Esta parte del nombre, TF, se refiere a la frecuencia con la que una palabra clave específica aparece en un documento. Mide cuántas veces una palabra clave ocurre en relación con el número total de palabras en ese documento. La idea es que una palabra clave que aparece con frecuencia en un documento es relevante para ese documento.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

2. **Frecuencia Inversa de Documento (IDF - Inverse Document Frequency):** La parte IDF mide cuán común o rara es una palabra clave en un conjunto de documentos más amplio. Un término que es raro en el conjunto de documentos, pero que aparece en un documento específico, se considera más importante para ese documento. El IDF se calcula como el logaritmo del inverso de la proporción de documentos que contienen la palabra clave.

La idea detrás de TF-IDF es identificar palabras clave que son relevantes para un documento específico, pero que también son distintivas y poco comunes en el conjunto de documentos en su totalidad. Cuanto más alta sea la puntuación TF-IDF de una palabra clave en un documento, más relevante y distintiva se considera.

La técnica TF-IDF se originó en el campo de la recuperación de información y se ha convertido en una herramienta esencial en el procesamiento de lenguaje natural, la clasificación de texto y la extracción de información. Ayuda a identificar las palabras clave más importantes en un documento y a mejorar la precisión en tareas como la búsqueda de información o la clasificación de texto.

2.2.2 Proceso de TF

La "Frecuencia de Término" (TF) es una medida que se utiliza para evaluar cuántas veces aparece una palabra clave específica en un documento con respecto al número total de palabras en ese documento. La idea detrás de TF es determinar cuán relevante es una palabra clave dentro de un documento específico. A continuación, se explica con más detalle cómo funciona:

1. **Conteo de ocurrencias de palabras clave:**
 - En esta etapa, se comienza por seleccionar una palabra clave específica que se desea evaluar en un documento dado.
 - Luego, se cuenta cuántas veces aparece esa palabra clave en ese documento en particular. Este recuento se basa en la aparición exacta de la palabra clave, no se tienen en cuenta sinónimos o variaciones.
2. **Normalización de frecuencia:**
 - Una vez que se ha realizado el recuento de ocurrencias, se normaliza la frecuencia dividiendo el número de veces que aparece la palabra clave por el número total de palabras en el documento. Esto ayuda a tener en cuenta la longitud del documento y garantiza que la medida sea relativa al tamaño del texto. La fórmula típica para calcular la Frecuencia de Término (TF) es:

Term Frequency ← $TF = \frac{t \in d}{T \in d}$

→ Cantidad de veces que un término figura en un documento

→ Cantidad de palabras totales en el documento

Ilustración 2-2: Fórmula del cálculo de TF (TF-IDF)

3. Interpretación:

- El resultado del cálculo de la Frecuencia de Término (TF) es un valor que indica la importancia relativa de la palabra clave 't' en el documento 'd'. Cuanto mayor sea el valor de TF, mayor será la importancia relativa de la palabra clave en ese documento en particular.
- Si el valor de TF es cercano a 0, significa que la palabra clave apenas aparece en el documento y, por lo tanto, no es muy relevante para ese contenido.

4. Valor por palabra clave y documento:

- Se calcula la Frecuencia de Término para cada palabra clave en el documento, lo que proporciona una medida de la relevancia de cada palabra clave en ese documento específico.

2.2.3 Proceso de IDF

La Frecuencia Inversa de Documento se utiliza para evaluar cuán común o rara es una palabra clave en un conjunto de documentos más amplio. La idea es identificar palabras clave que sean distintivas y poco comunes en el conjunto de documentos. A continuación, se explica en detalle cómo funciona la Frecuencia Inversa de Documento:

1. Conteo de documentos que contienen la palabra clave:

- Para calcular el valor de IDF para una palabra clave específica, primero se cuenta cuántos documentos en el conjunto de documentos contienen esa palabra clave. Es decir, se identifica en cuántos documentos aparece la palabra clave en cuestión.

2. Cálculo de la frecuencia inversa de documento (IDF):

- El cálculo de la Frecuencia Inversa de Documento (IDF) implica tomar el logaritmo del inverso de la proporción de documentos que contienen la palabra clave. La fórmula típica es:

Todos los documentos

↑

Inverse Document Frequency ← $IDF = \times \log \left(\frac{D}{\{d \in D : t \in d\}} \right)$

↓

la suma de todas las veces que figura
el término en todos los documentos

Ilustración 2-3: Fórmula del cálculo de IDF (TF-IDF)

3. Interpretación del valor IDF:

- El resultado del cálculo de IDF es un valor numérico que refleja la rareza o importancia relativa de la palabra clave en el contexto del conjunto de documentos.
- Si una palabra clave es muy común y aparece en la mayoría de los documentos, su valor IDF será bajo, lo que indica que no es particularmente distintiva.
- Si una palabra clave es rara y aparece solo en unos pocos documentos, su valor IDF será alto, lo que sugiere que es una palabra clave distintiva.

4. Valor por palabra clave:

- Se calcula el valor de IDF para cada palabra clave que se está evaluando en el conjunto de documentos. Cada palabra clave tendrá un valor de IDF único.

La Frecuencia Inversa de Documento (IDF) es esencial en TF-IDF porque le da peso a las palabras clave que son distintivas y raras en el conjunto de documentos. Cuando se multiplica con la Frecuencia de Término (TF), se obtiene el puntaje TF-IDF, que refleja la importancia relativa de una palabra clave en un documento en comparación con el conjunto de documentos en su totalidad.

2.2.4 Cálculo del puntaje

Finalmente, el puntaje TF-IDF para una palabra clave 't' en un documento 'd' se calcula multiplicando el puntaje de Frecuencia de Término (TF) por el puntaje de Frecuencia Inversa de Documento (IDF):

$$TF - IDF = TF \times IDF$$

Ilustración 2-4: Fórmula final del cálculo de TF-IDF

El puntaje TF-IDF resultante es una medida numérica que refleja la importancia relativa de la palabra clave 't' en el documento 'd' en comparación con el conjunto de documentos en su totalidad.

Las palabras clave con puntajes TF-IDF más altos se consideran más importantes y relevantes en el contexto del documento, ya que tienen una alta Frecuencia de Término en ese documento y una baja presencia en otros documentos (gracias a la Frecuencia Inversa de Documento).

En resumen, el puntaje TF-IDF se utiliza para identificar palabras clave en un documento en función de su relevancia y rareza en el conjunto de documentos. Es una herramienta importante en tareas como la búsqueda de información, la clasificación de texto y la extracción de palabras clave.

2.3 Análisis de resultados

El siguiente paso, una vez explicada la estructura del algoritmo, es el de analizar los resultados, es decir, cómo de efectivo es el algoritmo a la hora de hacer su labor. Para ello se usarán medidas que son de interés para medir la efectividad de sistemas en materia de recuperación de información, clasificadores... Asimismo, para medir esta efectividad se usarán unos textos de prueba, los cuales, se pueden ver en la bibliografía en las referencias [14]–[17]. Cada uno de estos libros están organizados en capítulos los cuales están en ficheros de texto. Para cada capítulo le acompaña un fichero de texto que almacena las palabras clave identificadas por la editorial. Con lo cual podemos evaluar la efectividad del algoritmo.

2.3.1 True Positive

Los Verdaderos Positivos (TP del inglés) son el número de valores que realmente son una buena solución. Aplicado a esta situación, los TP serían, de todas las palabras clave que el algoritmo extraiga, los términos que si se esperase que obtuviera como Keyword.

2.3.2 False Positive

Los Falsos Positivos (FP del inglés) son el número de valores que salen como correctos pero que realmente no son parte de la solución. Aplicado a esta situación, los FP serían, de todas las palabras clave que el algoritmo genere, los términos que no sean TP, es decir, palabras que el algoritmo saque como importantes pero que realmente no lo son o simplemente no se esperaba que salieran como Keyword.

2.3.3 True Negative

Los Verdaderos Negativos (TN del inglés) son el número de valores que no salen como parte de la solución y realmente no lo son. En el caso de nuestro problema, los TN serían, de todas las palabras que no salen en el conjunto de palabras clave, las que realmente no lo son y se acierta dejándolas fuera de dicho conjunto.

2.3.4 False Negative

Los Falsos Negativos (FN del inglés) son el número de valores que no salen incluidos en la solución pero que si deberían salir en ella. En cuanto a nuestra problemática, los FN serían, de todas las palabras que no están incluidas en los términos que marca el algoritmo, las que si se esperaban como palabras importantes y deberían estar.

2.3.5 Precisión (Precision)

La Precisión (Precision del inglés) es la ratio entre el número de documentos relevantes recuperados entre el número de documentos recuperados. Respecto a nuestro caso, la Precisión sería el número de TP (las keywords que hemos obtenido y son relevantes) dividido por TP + FP, es decir, el total de resultados del algoritmo representado por la suma de todos los positivos, tanto los verdaderos como los falsos.

$$Precision = \frac{TP}{TP + FP}$$

2.3.6 Exhaustividad (Recall)

La Exhaustividad (Recall del inglés) es la ratio que representa la proporción de documentos relevantes recuperados entre el total de los documentos que son relevantes existentes, independientemente de si son recuperados todos o no. En lo que nos afecta se podría definir al Recall como el número de TP (términos obtenidos y que realmente queríamos obtener, es decir, buenos resultados) dividido por TP + FN, lo cual representa el total de términos que se consideran importantes y por tanto deberían salir como resultados.




Ilustración 2-5: TP, TN, FP, FN visto gráficamente. Imagen sacada de Wikipedia.




Ilustración 2-6: Precisión y Exhaustividad visto gráficamente. Imagen sacada de Wikipedia.

2.3.7 F1 Score

Es considerada una media armónica que combina dos valores, el de la precisión y el de la exhaustividad (precisión y recall en inglés).

$$F1 = 2 \cdot \frac{precision \cdot recall}{precision + recall} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}$$

En este trabajo el F1 Score ha sido el valor que ha servido de guía para intentar obtener los mejores resultados posibles, permitiendo no solamente fijarse en cuántos términos de los que se querían conseguir se obtenían, sino también en el número total de keywords obtenidas, FP, FN...

2.3.8 Dataset

Para poder realizar prueba con los algoritmos fueron necesarios textos educativos que tuviesen ya marcadas las palabras clave dentro de un entorno educativo (las palabras que un profesor puede considerar para hacer preguntas o quiere que aprendan sus alumnos) para poder hacer pruebas y obtener el mejor algoritmo posible.

Al no existir datasets públicos de este estilo que pudiesen ser utilizados, se ha optado por aprovechar los resultados de una investigación en la que se buscaron libros de educación que tuviesen ya marcadas las keywords de cada tema y a partir de ahí crear un dataset propio. El dataset obtenido de dicha investigación contiene documentos de diferentes temáticas, sin embargo, para este proyecto se han necesitado solamente los focalizados en historia, ya que los tipos de palabras cambian notablemente dependiendo de la temática, por ejemplo, las palabras clave que pueden salir de un texto de física y las de uno de historia son muy diferentes.

A continuación, se muestran los datos de los textos del dataset utilizado:

2.3.8.1 Textos de '*US History*'

Texto	N.º de palabras	Palabras clave
01	7110	21
02	8707	34
03	9073	29
04	8408	23
05	9164	22
06	6846	14
07	8663	21
08	8644	25
09	8901	21
10	7377	31
11	9136	24
12	9193	17
13	7831	23
14	7802	22
15	10635	24

Tabla 1: Número de palabras y keywords de los textos de '*US History*'

2.3.8.2 Textos de *'The American Peageant'*

Texto	N.º de palabras	Palabras clave
01	6583	31
02	6322	30
03	8535	35
04	6088	15
05	8081	20
06	4825	21
07	7006	34
08	8098	33
09	9088	21
10	8425	29
11	7970	34
12	7823	32
13	10105	30
14	10128	33
15	9632	47

Tabla 2: Número de palabras y keywords de los textos de *'The American Peageant'*

2.3.8.3 Textos de *'Modern World History – Cambridge'*

Texto	N.º de palabras	Palabras clave
01	3674	30
02	6642	20

03	5218	15
04	2966	23
05	9029	40
06	5393	31
07	7153	15
08	12227	32
09	13871	28
10	15478	29

Tabla 3: Número de palabras y keywords de los textos de 'Modern World History - Cambridge'

2.3.8.4 Textos de 'From Yesterday To Tomorrow'

Texto	N.º de palabras	Palabras clave
01	1904	18
02	5176	29
03	3778	21
04	5273	23
05	4487	29
06	3761	25

Tabla 4: Número de palabras y keywords de los textos de 'From Yesterday To Tomorrow'

2.3.9 Análisis de resultados

A pesar de tener claro que se iba a partir de TF-IDF, en la fase de selección de algoritmo se realizaron pruebas con distintas opciones para comprobar cuál sería la mejor opción para trabajar sobre él. En las siguientes tablas se muestran los resultados obtenidos para varios algoritmos probados.

2.3.9.1 Analizando resultados de TextRank

El primer algoritmo con el que se realizaron pruebas fue el TextRank, a continuación, una muestra de los datos recogidos para los tres primeros textos de cada conjunto de documentos.

Texto	TP	FN	FP	P	R	F1
<i>The American Peageant</i> Text 01	5	23	1371	0,00363	0,17857	0,00712
<i>The American Peageant</i> Text 02	4	25	1249	0,00319	0,13793	0,00624
<i>The American Peageant</i> Text 03	3	31	1597	0,00188	0,08824	0,00367
<i>US History</i> Text 01	6	15	1393	0,00429	0,28571	0,00845
<i>US History</i> Text 02	7	27	1422	0,00490	0,20588	0,00957
<i>US History</i> Text 03	6	23	1358	0,00440	0,20690	0,00861
<i>Modern World History, Cambridge</i> Text 01	10	20	546	0,01799	0,33333	0,03413
<i>Modern World History,</i>	0	20	815	0	0	0

<i>Cambridge</i>						
<i>Text 02</i>						
<i>Modern World History, Cambridge</i>	0	15	660	0	0	0
<i>Text 03</i>						
<i>From Yesterday To Tomorrow</i>	9	9	380	0,02314	0,5	0,04423
<i>Text 01</i>						
<i>From Yesterday To Tomorrow</i>	17	12	885	0,01885	0,58621	0,03652
<i>Text 02</i>						
<i>From Yesterday To Tomorrow</i>	14	7	665	0,02062	0,66667	0,04000
<i>Text 03</i>						

Tabla 5: Datos recogidos aplicando TextRank a los tres primeros textos de cada conjunto

Con las siguientes medias:

MEDIAS	6,75	18,917	1028,42	0,00857	0,26579	0,01655
--------	------	--------	---------	---------	---------	---------

Tabla 6: Medias de los datos recogidos para TextRank sobre los tres primeros textos de cada conjunto

Como se ve en la tabla que muestra el conjunto de datos, algunas veces el algoritmo no muestra resultados de los esperados (TP), además, el F1 Score suele ser muy bajo excepto en los textos de ‘*From Yesterday To Tomorrow*’ en los que sube considerablemente debido a que disminuyen en gran medida los FP y se mantienen muy altos los TP.

2.3.9.2 Analizando resultados de TF-IDF básico

Tras haber probado TextRank, se realizaron pruebas con un TF-IDF básico, los resultados fueron los siguientes:

Texto	TP	FN	FP	P	R	F1
<i>The American Peageant</i> Text 01	12	16	5973	0,00201	0,42857	0,00399
<i>The American Peageant</i> Text 02	23	6	5737	0,00399	0,79310	0,00795
<i>The American Peageant</i> Text 03	24	10	7748	0,00309	0,70588	0,00615
<i>US History</i> Text 01	7	14	7003	0,00099	0,33333	0,00199
<i>US History</i> Text 02	18	16	9059	0,00198	0,52941	0,00395
<i>US History</i> Text 03	19	10	9816	0,00193	0,65517	0,00385
<i>Modern World History, Cambridge</i> Text 01	13	17	3194	0,00405	0,43333	0,00803
<i>Modern World History,</i>	8	12	6234	0,00128	0,40000	0,00256

<i>Cambridge</i>						
<i>Text 02</i>						
<i>Modern World History, Cambridge</i>	7	8	5134	0,00136	0,46667	0,00272
<i>Text 03</i>						
<i>From Yesterday To Tomorrow</i>	9	9	1552	0,00577	0,50000	0,01140
<i>Text 01</i>						
<i>From Yesterday To Tomorrow</i>	10	19	4696	0,00213	0,34483	0,00422
<i>Text 02</i>						
<i>From Yesterday To Tomorrow</i>	13	8	2863	0,00452	0,61905	0,00898
<i>Text 03</i>						

Tabla 7: Datos recogidos aplicando TF-IDF básico a los tres primeros textos de cada conjunto

Y con unas medias de:

MEDIAS	13,583	12,08	5750,75	0,00276	0,51745	0,00548
---------------	--------	-------	---------	---------	---------	---------

Tabla 8: Medias de los datos recogidos para TF-IDF básico sobre los tres primeros textos de cada conjunto

Comparando con TextRank se puede ver que TF-IDF no obtuvo, al menos en esta muestra, ningún documento en el que no contuviera ninguna palabra de las que son esperadas como importantes. Otra de las cosas a destacar es la baja media de F1 Score, la cual se debe en gran medida al alto número de FP que hay siempre, no bajan de 1500 en el mejor de los casos y esto perjudica en gran medida a esta media ya que, los TP son bastante altos comparados con los de TextRank (una media de aproximadamente el doble).

2.3.9.3 Analizando resultados de RAKE

Finalmente, una vez realizadas las pruebas con los dos primeros algoritmos, se llevaron a cabo las mismas pruebas con RAKE, con los siguientes resultados:

Texto	TP	FN	FP	P	R	F1
<i>The American Peageant</i> <i>Text 01</i>	11	17	1619	0,00675	0,39286	0,01327
<i>The American Peageant</i> <i>Text 02</i>	13	16	1566	0,00823	0,44828	0,01617
<i>The American Peageant</i> <i>Text 03</i>	15	19	2070	0,00719	0,44118	0,01416
<i>US History</i> <i>Text 01</i>	10	11	1798	0,00553	0,47619	0,01094
<i>US History</i> <i>Text 02</i>	18	16	2031	0,00879	0,52941	0,01728
<i>US History</i> <i>Text 03</i>	11	18	2118	0,00517	0,37931	0,01020
<i>Modern World History, Cambridge</i> <i>Text 01</i>	14	16	786	0,01750	0,46667	0,03374
<i>Modern World History,</i>	5	15	1325	0,00376	0,25000	0,00741

<i>Cambridge</i>						
<i>Text 02</i>						
<i>Modern World History, Cambridge</i>	5	10	1044	0,00477	0,33333	0,00940
<i>Text 03</i>						
<i>From Yesterday To Tomorrow</i>	9	9	429	0,02055	0,50000	0,03947
<i>Text 01</i>						
<i>From Yesterday To Tomorrow</i>	12	17	1181	0,01006	0,41379	0,01964
<i>Text 02</i>						
<i>From Yesterday To Tomorrow</i>	13	8	880	0,01456	0,61905	0,02845
<i>Text 03</i>						

Tabla 9: Datos recogidos aplicando RAKE a los tres primeros textos de cada conjunto

Y, a continuación, las medias resultantes de dichos datos:

MEDIAS	11,333	14,333	1403,92	0,00940	0,43751	0,01834
---------------	--------	--------	---------	---------	---------	---------

Tabla 10: Medias de los datos recogidos para RAKE sobre los tres primeros textos de cada conjunto

Como conclusión de los datos obtenidos con RAKE podemos decir que el F1 Score es algo mejor que la mejor marca hasta el momento, es decir, el mejor de los tres probados en este aspecto. También se puede destacar que por lo general los TP suelen ser bastante altos, no llegan a los resultados de TF-IDF básico obtenidos, pero son suficientemente buenos. En general podríamos decir que los resultados obtenidos con RAKE son similares a los obtenidos con TextRank.

2.3.9.4 Analizando resultados de TF-IDF modificado (algoritmo propuesto)

Tras llevar a cabo todas las modificaciones pertinentes en el algoritmo TF-IDF, se obtuvo un procedimiento modificado basado en el algoritmo mencionado pero cuyos resultados son muy superiores, a continuación, se muestran los mismos datos que se mostraron en los análisis de TextRank y TF-IDF básico, pero con los resultados obtenidos del nuevo algoritmo mejorado.

Texto	TP	FN	FP	P	R	F1
<i>The American Peageant</i> Text 01	3	25	51	0,05556	0,10714	0,07317
<i>The American Peageant</i> Text 02	3	26	68	0,04225	0,10345	0,06000
<i>The American Peageant</i> Text 03	2	32	74	0,02632	0,05882	0,03636
<i>US History</i> Text 01	3	18	75	0,03846	0,14286	0,06061
<i>US History</i> Text 02	4	30	102	0,03774	0,11765	0,05714
<i>US History</i> Text 03	5	24	100	0,04762	0,17241	0,07463
<i>Modern World History, Cambridge</i> Text 01	2	28	38	0,05000	0,06667	0,05714

Modern World History, Cambridge Text 02	3	17	60	0,04762	0,15000	0,07229
Modern World History, Cambridge Text 03	4	11	56	0,06667	0,26667	0,10667
From Yesterday To Tomorrow Text 01	0	18	4	0	0	0
From Yesterday To Tomorrow Text 02	1	28	29	0,03333	0,03448	0,03390
From Yesterday To Tomorrow Text 03	1	20	24	0,04000	0,04762	0,04348

Tabla 11: Datos recogidos aplicando TF-IDF modificado a los tres primeros textos de cada conjunto

Con sus respectivas medias:

MEDIAS	2,5833	23,08	56,75	0,04046	0,10565	0,05628
--------	--------	-------	-------	---------	---------	---------

Tabla 12: Medias de los datos recogidos para TF-IDF modificado sobre los tres primeros textos de cada conjunto

Simplemente comparando las medias de F1 Score se puede ver que este algoritmo es mejor (en ese sentido), a pesar de ello, el número de TP obtenido es pobre, apenas el 19% de los TP obtenidos de media en el TF-IDF básico. Lo mejor de este algoritmo es los

bajos números que muestra ante los FP, donde en el peor de los casos supera ligeramente los 100.

2.3.10 Conclusiones del estudio de algoritmos

Tras haber realizado pruebas con TextRank, RAKE, TF-IDF y una modificación de este último, se decidió utilizar la modificación de TF-IDF ya que, se obtuvieron mejoras significativas en el valor de F1 con pequeños ajustes y se vio en él un potencial de mejora mayor.

Se obtienen resultados pobres debido a la gran longitud de los textos con los que se realizaron las pruebas, de hasta 7000 palabras, esto hace que sea más complicado detectar las palabras más importantes. En numerosas ocasiones las palabras clave son muy específicas, además de, en muchos casos, estar formadas por más de una palabra, cuando en el algoritmo propuesto se están buscando palabras clave compuestas por un único término. A pesar de ello, el algoritmo propuesto (TF-IDF modificado) es el que mejores resultados ofrece para la mayoría de textos.

Se puede destacar de los datos recolectados que TF-IDF básico apenas obtiene resultados que se acerquen a los de otros algoritmos, en parte relacionado con el alto número de falsos positivos que muestra, llegando a 7000, factor que también afecta a RAKE, sin embargo, parece que obtiene un F1 bastante elevado en muchos de los casos, esto se debe a que, a pesar de haber comentado que tiene unas cifras de falsos positivos muy elevadas, estas no ascienden de los 2000 en ninguno de los casos de prueba, lo que denota una clara diferencia.

En el caso de TextRank lo que nos ofrece es un término medio, falsos positivos más controlados, pero verdaderos positivos más bajos, lo que hace que el F1 Score sea mediano, tirando a bajo en algunos casos, pero mostrando la mejor media en cuanto a los textos de *'From Yesterday To Tomorrow'*. Finalmente, el algoritmo modificado es el que ofrece, en reglas generales, mejores resultados y esto se debe en su mayoría al bajo número de falsos positivos que presenta, consiguiendo mantener un número estable de verdaderos positivos.

A continuación, se muestra una comparativa de las medias de F1 Score dependiendo del algoritmo y del conjunto de textos seleccionado.

	The American Peageant	US History	Modern World History	From Yesterday To Tomorrow
TF-IDF modificado (algoritmo propuesto)	0,05651	0,06413	0,07870	0,02579

TF-IDF básico	0,00603	0,00330	0,00443	0,00820
TextRank	0,00568	0,00888	0,01138	0,04025
RAKE	0,05700	0,01280	0,01685	0,02919

Tabla 13: Medias de F1 Score comparando algoritmos según el conjunto de textos

Se puede observar en la presente tabla lo comentado con anterioridad, las pruebas resultan favorables al algoritmo propuesto a pesar de haber situaciones en las que tanto RAKE como TextRank ofrecen una mejor solución, siendo TF-IDF básico siempre el que ofrezca la peor propuesta.

2.3.11 Algoritmo personalizado en profundidad

En este apartado se mostrarán más detalladamente pruebas realizadas con el algoritmo modificado a partir de TF-IDF básico.

2.3.11.1 Textos de ‘The American Peageant’

Texto	TP	FN	FP	P	R	F1
01	3	25	51	0,05556	0,10714	0,07317
02	3	26	68	0,04225	0,10345	0,06000
03	2	32	74	0,02632	0,05882	0,03636
04	0	14	37	0	0	0
05	0	19	56	0	0	0
06	2	17	52	0,03704	0,10526	0,05479
07	0	33	51	0	0	0
08	5	27	80	0,05882	0,15625	0,08547
09	0	21	58	0	0	0
10	0	29	64	0	0	0
11	2	32	100	0,01961	0,05882	0,02941
12	0	32	83	0	0	0

13	0	30	90	0	0	0
14	0	33	69	0	0	0
15	2	45	91	0,02151	0,04255	0,02857

Tabla 14: Aplicación del algoritmo modificado para los 15 primeros textos de 'The American Peageant'

Las medias resultantes para estos textos son las siguientes:

MEDIAS	1	28	68,3	0,01741	0,04215	0,02452
--------	---	----	------	---------	---------	---------

Tabla 15: Medias para el algoritmo modificado de los 15 primeros textos de 'The American Peageant'

En aproximadamente la mitad de los textos no se encontraron palabras clave que fuesen esperadas, es decir los TP son 0, sin embargo, el punto positivo de este algoritmo es que los FP no suelen ser superiores a 100, por tanto, suelen quedar buenos resultados. La media F1 Score final es un tanto baja debido a estos textos en los que las keywords correctas fueron 0.

2.3.11.2 Textos de 'US History'

Texto	TP	FN	FP	P	R	F1
01	3	18	75	0,03846	0,14286	0,06061
02	4	30	102	0,03774	0,11765	0,05714
03	5	24	100	0,04762	0,17241	0,07463
04	1	22	141	0,00704	0,04348	0,01212
05	1	21	98	0,01010	0,04545	0,01653
06	1	13	121	0,00820	0,07143	0,01471
07	2	19	91	0,02151	0,09524	0,03509
08	2	23	133	0,01482	0,08000	0,02500
09	0	21	61	0	0	0
10	2	29	102	0,01923	0,06452	0,02963
11	1	23	152	0,00654	0,04167	0,01130

12	0	17	76	0	0	0
13	1	22	87	0,01136	0,04348	0,01802
14	1	21	116	0,00855	0,04545	0,01439
15	1	23	122	0,00813	0,04167	0,01361

Tabla 16: Aplicación del algoritmo modificado para los 15 primeros textos de 'US History'

En cuanto a las medias obtenidas de estos textos:

MEDIAS	2	22	105	0,01595	0,06702	0,02552
--------	---	----	-----	---------	---------	---------

Tabla 17: Medias para el algoritmo modificado de los 15 primeros textos de 'US History'

Se puede observar a simple vista que el número de veces que sucede que los TP sean 0 es mucho menor que en los textos anteriores, sin embargo, la media de F1 Score se mantiene similar, en este caso debido a que los FP también aumentan en este tipo de documentos.

2.3.11.3 Textos de 'Modern World History – Cambridge'

Texto	TP	FN	FP	P	R	F1
01	2	28	38	0,05000	0,06667	0,05714
02	3	17	60	0,04762	0,15000	0,07229
03	4	11	56	0,06667	0,26667	0,10667
04	2	21	38	0,05000	0,08696	0,06349
05	2	38	71	0,02740	0,05000	0,03540
06	2	29	62	0,03125	0,06452	0,04211
07	3	13	58	0,04918	0,18750	0,07792
08	12	20	78	0,13333	0,37500	0,19672
09	9	19	102	0,08108	0,32143	0,12950
10	6	23	83	0,06742	0,20690	0,10170

Tabla 18: Aplicación del algoritmo modificado para los 10 textos de 'Modern World History - Cambridge'

Para dichos documentos, las medias fueron las siguientes:

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO
			JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es

MEDIAS	5	22	65	0,06039	0,17756	0,08829
--------	---	----	----	---------	---------	---------

Tabla 19: Medias para el algoritmo modificado de los 10 textos de 'Modern World History - Cambridge'

Con estos textos se obtuvieron los mejores datos, llegando en algunos casos a un F1 Score que rozaba el 0.2, además de tener una media que se acerca al 0.1 (0.088). Al igual que con los primeros textos, los FP vuelven a ser lo suficientemente bajos como para que cuando los TP son mínimamente aceptables, el F1 Score aumente de manera considerable.

2.3.11.4 Textos de 'From Yesterday To Tomorrow'

TOTAL	TP	FN	FP	P	R	F1
01	0	18	4	0	0	0
02	1	28	29	0,03333	0,03448	0,03390
03	1	20	24	0,04000	0,04762	0,04348
04	3	20	31	0,08824	0,13043	0,10526
05	3	26	46	0,06123	0,10345	0,07692
06	0	25	23	0	0	0

Tabla 20: Aplicación del algoritmo modificado para los 6 textos de 'From Yesterday To Tomorrow'

Y su conjunto de medias:

MEDIAS	1	23	26	0,03713	0,05266	0,04326
--------	---	----	----	---------	---------	---------

Tabla 21: Medias para el algoritmo modificado de los 6 textos de 'From Yesterday To Tomorrow'

De nuevo vuelven a aparecer algunos textos que no proporcionan buenos resultados en cuanto a TP, sin embargo, unos FP tan bajos hacen que la media de F1 Score sea aceptable y mejor que los dos primeros conjuntos de documentos.

2.3.11.5 Resumen de datos obtenidos y conclusiones

Para poder observar las medias de manera más cómoda, se presentan ahora en una tabla todas juntas.

Textos	TP	FN	FP	P	R	F1
--------	----	----	----	---	---	----

<i>The American Peageant</i>	1,267	27,667	68,267	0,01741	0,04215	0,02452
<i>US History</i>	1,667	21,733	105,133	0,01595	0,06702	0,02552
<i>Modern World History, Cambridge</i>	4,5	21,9	64,6	0,06039	0,17756	0,08829
<i>From Yesterday To Tomorrow</i>	1,333	22,833	26,167	0,03713	0,05266	0,04326

Tabla 22: Resumen de los datos para el algoritmo modificado mostrando medias de TP, FN, FP, Precision, Recall y F1 Score

En sombreado verde, se encuentran los datos que hacen destacar a los textos de ese conjunto de documentos como buenos datos y, en naranja, los que hacen que destaquen en el sentido contrario.

Se puede observar en la tabla que los FN se mantienen sobre los mismos números en todos los documentos, lo cual parece ser significativo.

2.3.12 Discusión de resultados

Ante los resultados obtenidos con el algoritmo que finalmente fue elegido y modificado, podemos decir que el rendimiento es muy bueno en comparación con las primeras instancias de los algoritmos propuestos.

En este apartado se discutirán cada conjunto de resultados buscando puntos de mejora, basados en la tabla xx (poner referencia de la que tiene cosas marcadas).

2.3.12.1 Discusión de los TP obtenidos

Textos	TP
<i>The American Peageant</i>	1,267
<i>US History</i>	1,667
<i>Modern World History, Cambridge</i>	4,500

<i>From Yesterday To Tomorrow</i>	1,333
-----------------------------------	-------

Tabla 23: Medias de los TP obtenidos para el algoritmo modificado con cada uno de los conjuntos de textos

La media de TP obtenidos para cada texto muestra que realmente se obtienen muy pocas keywords del conjunto objetivo. A pesar de ello, en los textos de ‘*Modern World History, Cambridge*’ el valor es bastante alto en comparación con los demás conjuntos de textos. La media total de TP, juntando los conjuntos de textos es de 2.11. Además, el máximo de TP obtenidos en las muestras tomadas es de 12, siendo esta la única vez que el valor de TP supera las 10 palabras, sin embargo, el número de veces que este valor es 0 es de 12.

2.3.12.2 Discusión de los FP obtenidos

Textos	FP
<i>The American Peageant</i>	68,267
<i>US History</i>	105,133
<i>Modern World History, Cambridge</i>	64,600
<i>From Yesterday To Tomorrow</i>	26,167

Tabla 24: Medias de los FP obtenidos para el algoritmo modificado con cada uno de los conjuntos de textos

Respecto al número de FP, se obtuvieron en general resultados aceptables (que se muestren alrededor de 50 términos extra no es algo que perjudique en gran medida a la aplicación). La media obtenida en global del conjunto de documentos es de 74, cifras razonables. En el caso del máximo de FP obtenidas en las muestras fue de 152, cifra que representa poco más del doble que la media, por otra parte, el mínimo sería de 4, en ese caso puntual los TP fueron 0 como era de esperar, el número de FP más bajo sin contar dicho caso especial fueron 23, el cual representa mejor un mínimo para esta variable.

2.3.12.3 Discusión de los FN obtenidos

Textos	FN
<i>The American Peageant</i>	27,667
<i>US History</i>	21,733
<i>Modern World History, Cambridge</i>	21,900

<i>From Yesterday To Tomorrow</i>	22,833
-----------------------------------	--------

Tabla 25: Medias de los FN obtenidos para el algoritmo modificado con cada uno de los conjuntos de textos

En cuanto a los FN obtenidos son muy similares los valores de unos conjuntos de documentos respecto a los otros, solamente varían en 5.934 desde el menor al mayor valor. Teniendo en cuenta que el número de palabras clave que se esperan suele rondar entre 15 y 30, se podría decir que los valores de FN son altos, pero no es algo que sorprenda considerando lo bajos que eran los valores de TP en casi todos los textos. Si nos referimos a la media de FN global, estaríamos en un valor de 23.85, siendo similar igualmente a los valores de las medias para cada conjunto de datos. Finalmente, el máximo y mínimo de los FN está en 45 y 11 respectivamente.

2.3.12.4 Discusión de los valores de Precision obtenidos

Textos	Precision
<i>The American Peageant</i>	0,0174066
<i>US History</i>	0,0159523
<i>Modern World History, Cambridge</i>	0,0603943
<i>From Yesterday To Tomorrow</i>	0,0371322

Tabla 26: Medias de la Precision obtenida para el algoritmo modificado con cada uno de los conjuntos de textos

La precisión representa el número de aciertos respecto al número total de palabras resultantes del algoritmo. De esta manera destaca el valor de la precisión para los textos de ‘*Modern World History, Cambridge*’ ya que casi duplica al segundo conjunto que mejor valor tiene para dicha variable. Al ser el máximo posible de la precisión 1, podemos darnos cuenta de que aún están lejos de ser perfectos. Si hablamos de la media absoluta de la precisión para todos los conjuntos de documentos obtendríamos un valor de 0.029. Por otra parte, el máximo estaría en 0.133 el cual es un valor notablemente bueno. Finalmente, el mínimo encajaría en 0 ya que hay casos, como ya se ha observado en los datos mostrados anteriormente, en los que los TP son 0 y por tanto la precisión no le queda otra que ser 0 también.

2.3.12.5 Discusión de los valores de Recall obtenidos

Textos	Recall
--------	--------

<i>The American Peageant</i>	0,0421536
<i>US History</i>	0,0670200
<i>Modern World History, Cambridge</i>	0,1775631
<i>From Yesterday To Tomorrow</i>	0,0526642

Tabla 27: Medias de la Recall obtenida para el algoritmo modificado con cada uno de los conjuntos de textos

La exhaustividad representa el número de aciertos comparados con el total de palabras clave esperadas, permitiendo así destacar de nuevo a los textos de ‘*Modern World History, Cambridge*’ ya que representa una media del 17.76% de las palabras clave que se esperaban contra un 6.7% que representa la media del segundo que mejor valor tiene en este aspecto. Al igual que la precisión, la exhaustividad tiene como valor máximo 1 (valor que se daría si se consiguiesen sacar todas las palabras clave que se esperaban, independientemente del número de FP obtenidos), por tanto, el valor de 0.178 de la media de dichos documentos comentados es un valor que no está tan lejos del máximo posible comparado con otros algoritmos. En cuanto al máximo de exhaustividad en los datos recogidos como muestra, tenemos un 0.375, o lo que es lo mismo, 37.5% de las palabras que se esperaban en ese caso en concreto, representa un valor muy bueno y, coincide con el valor máximo de la precisión (1.333) y el valor máximo de TP (12). Respecto al mínimo, estaría en 0, como cabía suponer teniendo en cuenta, al igual que en la precisión, que el valor de TP, en ocasiones, es 0.

2.3.12.6 Discusión de los valores de F1 Score obtenidos

Textos	F1 Score
<i>The American Peageant</i>	0,0245188
<i>US History</i>	0,0255174
<i>Modern World History, Cambridge</i>	0,0882929
<i>From Yesterday To Tomorrow</i>	0,0432605

Tabla 28: Medias de los F1 Score obtenidos para el algoritmo modificado con cada uno de los conjuntos de textos

Por último, el F1 Score que, como se puede observar, no llega en ninguna de las medias de los datos tomados en las pruebas a 0.1, a pesar de que se acerca en el caso de los documentos de ‘*Modern World History, Cambridge*’, ésta media representa la mejor media de los conjuntos de textos doblando a la segunda que mejor media tiene que son

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO
			JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es

los que forman el conjunto de '*From Yesterday To Tomorrow*'. Mirando la media global de F1 Score teniendo en cuenta todos estos conjuntos de ficheros de historia, obtenemos un resultado de 0.041. Respecto al máximo de esta variable, se encuentra en 0.197, rondando el 0.2, el cual es un resultado muy bueno y de nuevo coincide con los máximos de exhaustividad, precisión y TP. En cuanto al mínimo, se sitúa en este caso en 0, sin ser sorprendente, de nuevo, debido a las ocasiones en las que los TP toman el valor de 0.

3 Estudio de Viabilidad del Sistema

3.1 Análisis de sistemas similares

En este apartado se describirán algunos sistemas actuales, unos ofrecen unos servicios similares a los que se pretenden con este proyecto y otros no. El objetivo de este análisis es valorar ventajas y desventajas de dichos sistemas.

3.1.1 OpenAI GPT-3

GPT-3, desarrollado por OpenAI, es uno de los modelos de lenguaje más avanzados y versátiles que se utilizan para la generación de preguntas y respuestas, así como para una amplia gama de tareas de procesamiento de lenguaje natural.

3.1.1.1 Ventajas

- GPT-3 es uno de los modelos de lenguaje más avanzados y versátiles, lo que le permite generar preguntas de manera coherente y comprensible.
- Puede manejar una amplia variedad de temas y dominios, lo que lo hace adecuado para una gama diversa de aplicaciones.
- Es capaz de generar preguntas y respuestas de calidad en varios idiomas.

3.1.1.2 Desventajas

- La utilización de GPT-3 puede ser costosa, ya que implica tarifas de acceso a la API.
- La generación de preguntas puede ser excesiva o redundante en algunos casos debido a que utiliza conocimiento “externo” al texto, de manera que es posible que algunas de las preguntas que genera no aparezca de manera exacta en el temario.
- Tiene un ‘límite’ de tamaño del texto a introducir, es inviable pedirle que genere preguntas sobre un libro entero.

3.1.2 BERT (Bidirectional Encoder Representations from Transformers) (Google)

BERT es un modelo de lenguaje desarrollado por Google que se utiliza en la generación de preguntas y respuestas, así como en la comprensión de texto. Es ampliamente utilizado en motores de búsqueda y sistemas de procesamiento de lenguaje natural.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

3.1.2.1 Ventajas

- BERT es ampliamente utilizado en la generación de preguntas y respuestas debido a su capacidad para comprender el contexto y el significado de las palabras en una oración.
- Es eficaz en la comprensión de textos en varios idiomas.
- Utiliza técnicas de procesamiento de lenguaje natural avanzadas.

3.1.2.2 Desventajas

- Puede requerir un ajuste fino (fine-tuning) en aplicaciones específicas para obtener resultados óptimos.
- No genera preguntas directamente, sino que se usa principalmente en tareas de comprensión de texto.

3.1.3 T5 (Text-to-Text Transfer Transformer)

T5 es otro modelo de lenguaje desarrollado por Google que se enfoca en la conversión de texto de entrada en texto de salida. Esto lo hace adecuado para la generación de preguntas y respuestas.

3.1.3.1 Ventajas

- T5 es eficaz en la generación de preguntas y respuestas, así como en la conversión de texto de entrada en texto de salida.
- Puede aplicarse a una variedad de tareas de procesamiento de lenguaje natural.
- Ofrece una estructura "texto a texto" que facilita la generación de preguntas.

3.1.3.2 Desventajas

- Al igual que BERT, T5 puede requerir un ajuste fino para tareas específicas.

3.1.4 Quillionz

Quillionz es una herramienta en línea específicamente diseñada para la generación de preguntas basadas en texto. Es utilizada por educadores y creadores de contenido para crear cuestionarios y pruebas.

3.1.4.1 Ventajas

- Quillionz está diseñado específicamente para la generación de preguntas basadas en texto, lo que lo hace fácil de usar para educadores y creadores de contenido.
- Permite a los usuarios generar cuestionarios y pruebas de manera eficiente.
- Proporciona una interfaz amigable y accesible en línea.

3.1.4.2 Desventajas

- Puede tener limitaciones en la complejidad de las preguntas que genera en comparación con modelos de lenguaje más avanzados.

3.1.5 Semantha

Semantha es una herramienta de generación de preguntas que utiliza el procesamiento de lenguaje natural para crear preguntas basadas en un texto de entrada. Es utilizado en campos educativos y de capacitación.

3.1.5.1 Ventajas

- Semantha utiliza técnicas de procesamiento de lenguaje natural para generar preguntas a partir de textos.
- Es útil en campos educativos y de capacitación.

3.1.5.2 Desventajas

- Puede tener un alcance más limitado en comparación con modelos de lenguaje avanzados como GPT-3 y BERT.
- Puede requerir ajustes adicionales para aplicaciones específicas.

3.2 Valoración de Alternativas de Solución

En este apartado se mostrarán las diferentes alternativas que se podrían usar para obtener una solución. En caso de ser necesario, se valorarán ventajas y desventajas de las opciones que se comenten.

3.2.1 Alternativas de enfoque del algoritmo

Las posibles alternativas al algoritmo elegido y modificado se muestran en el apartado 2.1.1.

3.2.2 Desarrollo del back-end de la aplicación

3.2.2.1 Node.js

Node.js es un entorno de ejecución de JavaScript del lado del servidor que es altamente escalable y eficiente en términos de rendimiento. Es especialmente popular en aplicaciones web en tiempo real y aplicaciones de una sola página (SPA) debido a su capacidad para manejar eventos de forma eficiente.

- **Última Versión:** Node.js 16.13.0 (a partir de octubre de 2023)
- **Desarrollador:** Node.js es un proyecto de código abierto y cuenta con una amplia comunidad de colaboradores. La Fundación Node.js proporciona liderazgo técnico y gobernanza.
- **Sitio web de Node.js**

3.2.2.2 Ruby on Rails

Ruby on Rails es un marco de desarrollo web basado en el lenguaje Ruby que se centra en la simplicidad y la productividad. Es conocido por su estructura de convención sobre configuración (CoC) y su enfoque en la programación orientada a objetos.

- **Última Versión:** Ruby on Rails 7.0 (a partir de septiembre de 2023)
- **Desarrollador:** Ruby on Rails es desarrollado por una comunidad de programadores y liderado por David Heinemeier Hansson.
- **Sitio web de Ruby on Rails**

3.2.2.3 Django (Python)

Django es un marco de desarrollo web en Python que se destaca por su facilidad de uso y su enfoque en la seguridad. Ofrece una gran cantidad de bibliotecas y módulos para acelerar el desarrollo y es especialmente adecuado para aplicaciones web complejas.

- **Última Versión:** Django 4.2 (a partir de abril de 2023)
- **Desarrollador:** Django es un proyecto de código abierto desarrollado por una comunidad activa y liderado por la Django Software Foundation.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

- **Sitio web de Django**

3.2.2.4 Spring (Java)

Spring es un framework de desarrollo de aplicaciones empresariales en Java. Es conocido por su robustez y se utiliza comúnmente en aplicaciones empresariales y sistemas de alta disponibilidad. Ofrece una amplia gama de módulos y extensiones.

- **Última Versión:** Spring Framework 5.3.9 (a partir de octubre de 2023)
- **Desarrollador:** Spring Framework es desarrollado por Pivotal Software, una división de VMware.
- **Sitio web de Spring Framework**

3.2.2.5 ASP.NET (C#)

ASP.NET es un marco de desarrollo web de Microsoft que se basa en el lenguaje C#. Ofrece una amplia gama de herramientas y bibliotecas para el desarrollo de aplicaciones web y es una opción popular en el mundo empresarial.

- **Última Versión:** ASP.NET Core 6.0 (a partir de noviembre de 2022)
- **Desarrollador:** ASP.NET Core es desarrollado por Microsoft.
- **Sitio web de ASP.NET Core**

3.2.2.6 Flask (Python)

Flask es un microframework de Python para el desarrollo web que se centra en la simplicidad y la extensibilidad. Es una opción popular para aplicaciones web pequeñas y rápidas.

- **Última Versión:** Flask 2.1 (a partir de septiembre de 2023)
- **Desarrollador:** Flask es desarrollado por Armin Ronacher y la comunidad de desarrolladores de Python.
- **Sitio web de Flask**

3.2.2.7 Symfony (PHP)

Symfony es un framework de desarrollo web en PHP que se enfoca en la modularidad y la reutilización de componentes. Es adecuado para aplicaciones web de cualquier tamaño.

- **Última Versión:** Symfony 6.0 (a partir de diciembre de 2022)

- **Desarrollador:** Symfony es desarrollado por SensioLabs y una comunidad activa de desarrolladores de PHP.
- **Sitio web de Symfony**

3.2.2.8 Decisión final de la tecnología a usar para implementación del back-end

	Rendimiento	Escalabilidad	Tendencias y futuro	Comunidad y soporte	Documentación y recursos de aprendizaje
Node.js	<i>Node.js es conocido por su rendimiento en aplicaciones web en tiempo real y aplicaciones de una sola página.</i>	<i>Escala eficazmente y se utiliza en aplicaciones en tiempo real y sistemas de alta concurrencia.</i>	<i>Node.js sigue siendo popular y tiene un futuro sólido en el desarrollo web.</i>	<i>Tiene una comunidad activa y una amplia gama de bibliotecas y módulos disponibles.</i>	<i>Ofrece documentación sólida y una gran cantidad de recursos de aprendizaje en línea.</i>
Ruby on Rails	<i>Es conocido por su facilidad de desarrollo, pero su rendimiento a veces puede ser inferior en comparación con algunos otros frameworks.</i>	<i>Puede escalar mediante técnicas como la fragmentación de bases de datos y el uso de caché.</i>	<i>Sigue siendo una opción popular para el desarrollo rápido de aplicaciones web. Aunque ha disminuido su popularidad en algunos casos, sigue siendo ampliamente utilizado.</i>	<i>Tiene una comunidad activa y foros de ayuda. Sin embargo, su popularidad ha disminuido en comparación con algunos otros frameworks.</i>	<i>Tiene documentación sólida y numerosos recursos de aprendizaje en línea.</i>
Django	<i>Es eficiente y ofrece buen rendimiento, especialmente cuando se</i>	<i>Puede escalar bien y se utiliza en aplicaciones</i>	<i>Sigue siendo popular y tiene un futuro sólido en el</i>	<i>Cuenta con una gran comunidad de desarrolladores y una</i>	<i>Ofrece una documentación completa y tutoriales en línea.</i>

	<i>utiliza con una configuración adecuada.</i>	<i>de gran envergadura.</i>	<i>desarrollo web.</i>	<i>abundancia de recursos.</i>	
Spring	<i>Es conocido por su rendimiento y escalabilidad en aplicaciones empresariales.</i>	<i>Se destaca en aplicaciones empresariales y sistemas de alta disponibilidad.</i>	<i>Sigue siendo una opción sólida para aplicaciones empresariales y tiene un futuro prometedor.</i>	<i>Cuenta con una comunidad activa y soporte empresarial.</i>	<i>Tiene una documentación exhaustiva y recursos de aprendizaje disponibles.</i>
ASP.NET	<i>Es conocido por su rendimiento en el desarrollo de aplicaciones web en el ecosistema de Microsoft.</i>	<i>Se utiliza comúnmente en aplicaciones empresariales y puede escalar eficazmente.</i>	<i>ASP.NET sigue siendo una elección sólida para el desarrollo de aplicaciones en el ecosistema de Microsoft.</i>	<i>Cuenta con una comunidad activa y soporte de Microsoft.</i>	<i>Microsoft ofrece documentación completa y recursos de aprendizaje.</i>
Flask	<i>Flask es ligero y ofrece un buen rendimiento, especialmente para aplicaciones web pequeñas y rápidas.</i>	<i>Es adecuado para aplicaciones más pequeñas y proyectos simples.</i>	<i>Flask sigue siendo popular para aplicaciones pequeñas y proyectos sencillos.</i>	<i>Cuenta con una comunidad activa, pero no es tan grande como algunas otras comunidades de frameworks más grandes.</i>	<i>Ofrece documentación sólida y recursos de aprendizaje.</i>
Symfony	<i>Symfony es eficiente y ofrece un buen rendimiento.</i>	<i>Es adecuado para aplicaciones web de cualquier tamaño.</i>	<i>Symfony sigue siendo popular en el desarrollo web y tiene un futuro sólido.</i>	<i>Cuenta con una comunidad activa y soporte profesional disponible.</i>	<i>Tiene una documentación completa y recursos de aprendizaje en línea.</i>

Tabla 29: Comparativa de tecnologías a aplicar en el back-end de la aplicación

Finalmente, tras observar la comparativa de alternativas, se ha optado por usar Node.js con Express.js (Express.js es un marco de desarrollo ligero y flexible para Node.js. Es

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO
			JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es

ampliamente utilizado para crear API RESTful y aplicaciones web simples y escalables. Su comunidad activa y su enfoque en la creación de servidores HTTP lo hacen popular para aplicaciones web y API.) ya que no es nuevo para mí, además de usar JavaScript, lenguaje que me gusta y domino. Otro factor determinante es la cantidad de documentación y soporte que hay acerca de Node.js.

3.2.3 Desarrollo del front-end de la aplicación web

Hoy en día son muchas las tecnologías que permiten crear aplicaciones web, sin embargo, son las que permiten crear Single Page Applications (SPA) las que están en auge, debido a que minimizan las recargas de página permitiendo actualizar partes del sitio sin realizar estas recargas. El objetivo de las aplicaciones de una sola página es permitir una navegación más fluida y mejor experiencia del usuario.

3.2.3.1 React

React es una biblioteca de JavaScript desarrollada por Facebook que es ampliamente utilizada en la creación de SPAs. Permite la construcción de interfaces de usuario interactivas y es altamente modular, lo que facilita la creación de componentes reutilizables.

- **Última Versión:** React 18 (a partir de 2023)
- **Desarrollador:** React es una biblioteca de código abierto desarrollada por Facebook y una comunidad activa de desarrolladores.
- **Sitio web de React**

3.2.3.2 Vue.js

Vue.js es un framework de JavaScript que se utiliza para la creación de SPAs. Es conocido por su facilidad de uso y su capacidad para integrarse con proyectos existentes.

- **Última Versión:** Vue.js 3 (a partir de 2023)
- **Desarrollador:** Vue.js es un proyecto de código abierto desarrollado por Evan You y una comunidad activa de colaboradores.
- **Sitio web de Vue.js**

3.2.3.3 Angular

Angular es un framework de JavaScript desarrollado por Google. Proporciona una estructura completa para la creación de SPAs y ofrece una serie de características poderosas, como enrutamiento, inyección de dependencias y una arquitectura MVC.

- **Última Versión:** Angular 13 (a partir de 2023)
- **Desarrollador:** Angular es un framework de código abierto desarrollado por Google y una comunidad activa de desarrolladores.
- **Sitio web de Angular**

3.2.3.4 Decisión final de la tecnología a usar para implementación del front-end

	Rendimiento	Escalabilidad	Tendencias y futuro	Comunidad y soporte	Documentación y recursos de aprendizaje
React	React es conocido por su rendimiento y eficiencia en la representación del DOM virtual. La reconciliación del DOM virtual minimiza las actualizaciones en el DOM real, lo que mejora el rendimiento.	React es escalable y se puede utilizar en aplicaciones de cualquier tamaño. Sin embargo, la gestión del estado puede requerir bibliotecas adicionales.	React sigue siendo una tecnología popular y tiene un futuro sólido. La introducción de React Server Components muestra un compromiso continuo con la innovación.	React tiene una comunidad de desarrolladores activa y el respaldo de Facebook e Instagram. También hay numerosas bibliotecas y herramientas de terceros disponibles.	React ofrece documentación detallada, tutoriales y una amplia gama de recursos en línea, incluyendo cursos y videos.
Vue.js	Vue es conocido por su rendimiento y eficiencia en la representación del DOM. El sistema de reactividad de Vue garantiza actualizaciones eficientes del DOM.	Vue es escalable y se adapta a aplicaciones de todos los tamaños. La estructura modular facilita la gestión del estado en aplicaciones grandes.	Vue sigue siendo una tecnología popular y tiene un futuro prometedor. El equipo de Vue está comprometido con la mejora continua.	Vue tiene una comunidad de desarrolladores activa y creciente. También se beneficia de un soporte empresarial.	Vue ofrece una documentación completa y una amplia gama de tutoriales y recursos de aprendizaje en línea.

Angular	Angular es conocido por su rendimiento en aplicaciones de gran envergadura, aunque su curva de aprendizaje puede influir en la optimización del rendimiento.	Angular es altamente escalable y se adapta bien a aplicaciones empresariales complejas.	Angular sigue siendo una tecnología popular en el desarrollo empresarial y tiene un futuro sólido. Google y una comunidad activa respaldan su desarrollo.	Angular cuenta con una comunidad activa y respaldo de Google. También ofrece soporte empresarial y herramientas de prueba.	Angular proporciona documentación exhaustiva y recursos de aprendizaje, incluyendo cursos en línea y material de capacitación.
---------	--	---	---	--	--

Tabla 30: Comparativa de tecnologías a aplicar en el front-end de la aplicación

Finalmente, y a pesar de no conocer mucho sobre ello, se decidió realizar el front-end con React debido al rendimiento y sobre todo a lo usado que es actualmente, lo que hace que tenga una comunidad muy activa y haya bastante información acerca del mismo.

4 Planificación y Gestión del Proyecto

En esta sección se muestra el informe detallado con la planificación temporal y con el presupuesto estimado del proyecto.

4.1 Planificación

El desarrollo de este proyecto tuvo diferentes fases que se llevaron a cabo en distintos tiempos, para detallarlo, se muestra a continuación un resumen:

Fase	Descripción
Planteamiento inicial y selección del algoritmo a modificar	Realizar una batería de muestras con los distintos algoritmos y textos de prueba para determinar con cuál se trabajaría en adelante, seleccionando no solo el que mejores resultados diese, sino fijándose también en la facilidad para realizar modificaciones y en la comprensión del algoritmo.
Modificación del algoritmo	Llevar a cabo las modificaciones que nos permitan pasar de un TF-IDF básico con resultados bastante malos a un TF-IDF mejorado que obtiene un rendimiento de gran calidad.
Análisis y diseño de la aplicación	Primer contacto, análisis y diseño de la aplicación a diseñar, comenzando en este momento con la documentación del proyecto.
Creación del servicio web	Creación de un servicio que tuviese distintos Endpoints y realizase distintas acciones en función de a cuál se llamase, entre ellos la funcionalidad de extracción de palabras clave.
Creación de la aplicación web	Creación de una aplicación React para representar gráficamente en una herramienta en línea los resultados del algoritmo, realizando peticiones al servicio web creado con anterioridad.

Pruebas	Realización de pruebas para comprobar el correcto funcionamiento de todos los endpoints de la Apirest.
Despliegue de la aplicación web	Realización del despliegue de la aplicación React para poder acceder a ella en línea, es decir, sin necesidad de tenerla en la red local.
Despliegue del servicio web	Realización del despliegue del Back-end con los distintos Endpoints para que la aplicación web pueda acceder a los servicios de manera remota.
Realización de la documentación	Realización de la documentación se realiza de continuo durante todo el proceso. Se muestran con precisión los detalles del sistema. Al final del proyecto se hará una revisión de la documentación.

Tabla 31: Descripción de las fases de planificación del proyecto




Ilustración 4-1: Planificación inicial del proyecto mostrado en un documento Project




Ilustración 4-2: Planificación final del proyecto mostrado en un documento Project

En las imágenes 4-1 y 4-2, se puede observar la distribución inicial del tiempo y cómo, al tener que presentar finalmente en noviembre, la planificación cambió radicalmente en la final.

En un principio se pretendía realizar un trabajo intenso durante los meses de junio y julio para intentar presentar en la convocatoria correspondiente, sin embargo, llegado un punto se vio que no era viable y se decidió participar en la siguiente convocatoria, cambiando de esta manera la planificación. Inicialmente se esperaba trabajar entre 8 y 10 horas diarias para compensar la falta de días, aun así, como se comenta, no fue viable debido al escaso tiempo del que se disponía.

Tras el verano, y como ya se ha indicado, la planificación cambió y pasó a ser la de la imagen 4-2, permitiendo el desarrollo de la aplicación durante los meses de septiembre, octubre y noviembre. En esta segunda etapa del desarrollo las horas aplicadas a cada día de trabajo fueron alrededor de 5.

De esta manera, el proyecto ocupó aproximadamente 58 días, de los cuales los primeros 27 fueron de mayor intensidad (8 horas diarias como se indica en este mismo apartado) y los restantes 31 de una menor carga. Finalmente, el total del trabajo da una suma de 371 horas, distribuidas de la siguiente manera:

Fase	Días
Planteamiento inicial y selección del algoritmo a modificar	3
Modificación del algoritmo	7
Análisis y diseño de la aplicación	2
Creación del servicio web	2
Creación de la aplicación web	9
Pruebas	1
Despliegue de la aplicación web	2
Despliegue del servicio web	3
Mejora de la aplicación web	16
Realización de la documentación	15
TOTAL	60

Tabla 32: Desglose de días por tarea de la planificación

A pesar de salir 60 días, el tiempo que ocupó fueron 58, como se indicó con anterioridad, esto es debido a que una de las tareas se realizó de manera paralela al resto, la cual fue el despliegue del servicio web.

4.2 Riesgos

4.2.1 Plan de gestión de riesgos

Para ver qué se va a detallar en este apartado, consultar el punto de los anexos 13.1.

4.2.2 Valoración de riesgos

En esta fase se mostrarán los detalles de los resultados de los procesos de identificación, análisis y priorización de riesgos.

4.2.2.1 Identificación de riesgos

ID	Categoría	Nombre	Descripción
Ri_1	Técnico	Problemas con las tecnologías utilizadas	El uso de React es relativamente nuevo por parte del trabajador. No pasa lo mismo con relación a Node.js, con el cual tiene algo más de experiencia, a pesar de tampoco ser amplia. Estos factores son determinantes a la hora de afrontar un proyecto como el que acontece, ya que la fase de adaptación puede resultar costosa.
Ri_2	Gestión	Comunicación con el tutor	La comunicación con el tutor en trabajos como este es una parte esencial, en ocasiones aportando soluciones a problemas determinados y en otras aportando ideas. Cabe la posibilidad de que el tutor no se encuentre disponible en determinados momentos y eso afectaría al desarrollo.
Ri_3	De organización	Trabajador no disponible	En este proyecto solamente se cuenta con un único trabajador, es por ello que podría darse la situación en la que se encuentre

			indispuesto o sea inviable continuar con el proyecto por determinados motivos.
Ri_4	Externo	Problemas con el equipo físico de desarrollo	El equipo en el que se llevará a cabo el desarrollo del proyecto tiene más de cuatro años. Estos equipos se deterioran, fallan y a veces es necesario cambiarlos. Es necesario contemplar la posibilidad de que esto suceda.
Ri_5	Gestión	Carga de trabajo	El inicio del proyecto se desarrolló durante el último cuatrimestre del grado, en el cual había que lidiar con la carga de trabajo de otras dos asignaturas, así como con las prácticas en empresa obligatorias. La segunda fase de desarrollo se ha llevado a cabo durante el inicio del Máster Universitario en Ingeniería Web, en el cual también hay una carga de trabajo continua.

Tabla 33: Riesgos identificados

4.2.2.2 Análisis de riesgos

En esta fase, se asociará a cada riesgo una probabilidad de que suceda y un impacto en cuanto a cuatro aspectos determinantes, presupuesto, planificación, alcance y calidad.

ID	Probabilidad	Impacto			
		Presupuesto	Planificación	Alcance	Calidad
Ri_1	Muy Alta	Bajo	Alto	Medio	Muy Alto
Ri_2	Media	Bajo	Alto	Medio	Medio
Ri_3	Media	Bajo	Muy Alto	Alto	Alto
Ri_4	Media	Alto	Bajo	Bajo	Bajo
Ri_5	Alta	Muy Bajo	Alto	Medio	Medio

Tabla 34: Probabilidad e impacto tras análisis de riesgos

4.2.2.3 Priorización de riesgos

Probabilidad	Muy Alta	0,90	0,05	0,14	0,27	0,50	0,81
	Alta	0,70	0,04	0,11	0,21	0,39	0,63
	Media	0,50	0,03	0,08	0,15	0,28	0,45
	Baja	0,30	0,02	0,05	0,09	0,17	0,27
	Muy Baja	0,10	0,01	0,02	0,03	0,06	0,09
			0,05	0,15	0,30	0,55	0,90
			Muy Bajo	Bajo	Medio	Alto	Muy Alto
			Impacto				

Tabla 35: Matriz de impacto y probabilidad

A continuación, y utilizando la matriz previamente mostrada, se calculará para cada riesgo su impacto con un valor en un rango de 0 a 1, donde 1 representa el mayor impacto y 0 el mínimo. De esta manera se ordenarán los riesgos en función de su impacto.

ID	Impacto
Ri_1	0,81
Ri_3	0,45
Ri_5	0,39
Ri_2	0,28
Ri_4	0,28

Tabla 36: Riesgos priorizados por su impacto calculado

4.2.3 Gestión de riesgos

4.2.3.1 Planificación de gestión de cada riesgo

A continuación, se indican las estrategias tomadas con respecto a cada riesgo:

ID	Nombre	Respuesta	Estrategia
Ri_1	Problemas con las tecnologías utilizadas	A pesar de ser un gran problema, es habitual en los proyectos informáticos, es por ello que se debe aceptar que sucederá.	Asumir
Ri_3	Trabajador no disponible	Debemos aceptar que podamos estar cierto tiempo de baja. Estas cosas nunca están previstas, pero es algo muy común.	Asumir
Ri_5	Carga de trabajo	Ante el trabajo externo que pueda aparecer siempre puede realizarse una buena planificación, pero cuando se trata de realizar varias cosas a la vez, siempre acaban influyendo las unas en las otras. Se debe aceptar que nos afectará.	Asumir
Ri_2	Comunicación con el tutor	Se debe evitar el retraso de las comunicaciones, es decir, la comunicación tiene que ser continua, informando de los avances, dudas o estancamientos, es por ello que debería poder mitigarse siguiendo estas pautas.	Mitigación
Ri_4	Problemas con el equipo físico de desarrollo	A pesar de cuidar al máximo el equipo, es inevitable que esto pueda suceder. En caso de ser así, se aceptaría.	Asumir

4.2.3.2 Resolución de riesgos

No se realizará una resolución de riesgos en este proyecto.

4.2.3.3 Monitorización de riesgos

Al igual que la resolución, no se ejecutará la monitorización de los riesgos.

4.3 Presupuesto

4.3.1 Gastos de personal

Concepto	N.º de personas	Horas	Coste
Ingeniero del software	1	320	40 €/hora
TOTAL			12800 €

Tabla 37: Descripción del presupuesto: Gastos en personal

4.3.2 Material y licencias

En este apartado se tendrá en cuenta que el proyecto ha sido desarrollado a lo largo de un total de 7 meses.

Concepto	Unidades	Precio / mes	Gasto total
Suministros (electricidad, agua, oficina...)	-	658,98 €	4612,86 €
Licencia Microsoft Project 2019	1	27 €	189 €
Licencia Office 365	1	11,70 €	81,90 €
TOTAL			4883,76 €

Tabla 38: Descripción del presupuesto: Gastos en material y licencias

4.3.3 Total de los costes

Concepto	Coste
Gastos del personal	12800 €
Gastos de material y licencias	4883,76 €
Total (sin IVA)	17683,76 €
Total (con IVA)	21397,35 €
Porcentaje de beneficios	72,38 %

Tabla 39: Descripción del presupuesto: Costes finales

5 Análisis del Sistema de Información

5.1 Determinación del Alcance del Sistema

En este apartado se indicarán los límites del sistema, es decir, su alcance. El sistema tendrá dos actores principales, usuarios autenticados como alumnos y usuarios autenticados como profesores, ambos con funcionalidades diferentes.

Por una parte, los usuarios autenticados como alumnos solamente podrán acceder a las vistas de realización de exámenes, los cuales habrán sido publicados por los usuarios autenticados como profesores.

Por otra parte, los usuarios autenticados como profesores dispondrán del resto de funcionalidades, las cuales son indicar texto para su procesamiento, extracción de palabras clave del mismo, gestión de dichas palabras clave (añadir alguna, seleccionar las que serán elegidas para generar las preguntas...) y gestión de preguntas generadas (editar pregunta o respuesta, eliminar preguntas...).

Al margen de los usuarios autenticados, los usuarios no autenticados no podrán realizar ninguna función en la aplicación, para comenzar a utilizarla es necesario darse de alta.

5.2 Identificación de Actores del Sistema

Los principales actores que interactuarán con el sistema son los siguientes:

- **Usuario autenticado como alumno:** este actor representa a cualquier usuario que se identifique como estudiante y cuya intención y capacidad es únicamente buscar y realizar exámenes. Se limitará únicamente a la funcionalidad mencionada.
- **Usuario autenticado como profesor:** este actor, sin embargo, dispondrá de más funcionalidades, será el que realice los exámenes, con todos los pasos que esto conlleva.

5.3 Establecimiento de Requisitos

5.3.1 Obtención de los Requisitos del Sistema

Este apartado determina la obtención de requisitos y para otorgarle una estructura se ha utilizado la especificación IEEE 830.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

5.3.1.1 Requisitos de interfaces externas

5.3.1.1.1 *Requisitos de interfaces de usuario*

R_INT_US_1. El sistema será accesible para los usuarios en los siguientes navegadores:

R_INT_US_1.1. Mozilla Firefox

R_INT_US_1.2. Google Chrome

R_INT_US_1.3. Microsoft Edge

R_INT_US_1.4. Opera

R_INT_US_2. El sistema proporcionará una interfaz adaptable hasta las siguientes resoluciones:

R_INT_US_2.1. Mínimo 1080x720

R_INT_US_2.2. Máximo 1920x1080

R_INT_US_3. El sistema estará internacionalizado para los siguientes idiomas:

R_INT_US_3.1. Español

5.3.1.2 Requisitos funcionales

5.3.1.2.1 *Página principal*

R_PAG_PRIN_1. El sistema mostrará la página principal a todos los usuarios ya estén autenticados o no.

5.3.1.2.2 *Gestión de usuarios*

R_US_1. El sistema permitirá a los usuarios no autenticados registrarse.

R_US_1.1. El usuario no autenticado introducirá los siguientes datos obligatorios:

R_US_1.1.1. Tipo de cuenta

R_US_1.1.1.1. El sistema validará que el tipo de cuenta esté seleccionado.

R_US_1.1.1.2. El tipo de cuenta debe ser de uno de los dos siguientes tipos:

R_US_1.1.1.2.1. Profesor

R_US_1.1.1.2.2. Estudiante

R_US_1.1.2. Nombre

R_US_1.1.2.1. El sistema validará que el nombre no sea vacío.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

R_US_1.1.2.2. El sistema validará que el nombre no contenga más de 24 caracteres.

R_US_1.1.3. Apellido

R_US_1.1.3.1. El sistema validará que el apellido no sea vacío.

R_US_1.1.3.2. El sistema validará que el apellido no contenga más de 24 caracteres.

R_US_1.1.4. Email

R_US_1.1.4.1. El sistema validará que el email no sea vacío.

R_US_1.1.4.2. El sistema validará que el email no contenga más de 24 caracteres.

R_US_1.1.4.3. El sistema validará que el email no esté asociado a otra cuenta.

R_US_1.1.5. Contraseña

R_US_1.1.5.1. El sistema validará que la contraseña no sea vacía.

R_US_1.1.5.2. El sistema validará que la contraseña contenga al menos ocho caracteres.

R_US_1.1.5.3. El sistema validará que la contraseña contenga al menos una letra mayúscula.

R_US_1.1.5.4. El sistema validará que la contraseña contenga al menos una letra minúscula.

R_US_1.1.5.5. El sistema validará que la contraseña contenga al menos un dígito.

R_US_1.1.5.2. El sistema validará que la contraseña no contenga más de 24 caracteres.

R_US_1.1.6. Confirmación de la contraseña

R_US_1.1.6.1. El sistema validará que la confirmación de la contraseña sea idéntica a la contraseña (R_US_1.1.5.).

R_US_1.1.7. El sistema, en caso de no cumplirse alguna de las validaciones, mostrará un mensaje al usuario y no permitirá llevar a cabo el registro.

R_US_1.1.8. El sistema, en caso de cumplir todas las validaciones, guardará los datos introducidos en la base de datos y permitirá el acceso a la aplicación.

R_US_2. El sistema permitirá a los usuarios registrados iniciar sesión.

R_US_2.1. El sistema solicitará los siguientes datos obligatorios:

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

R_US_2.1.1. Tipo de cuenta.

R_US_2.1.1.1. El sistema validará que el tipo de cuenta esté seleccionado.

R_US_2.1.1.2. El tipo de cuenta debe ser de alguno de los dos siguientes tipos:

R_US_2.1.1.2.1. Profesor

R_US_2.1.1.2.2. Estudiante

R_US_2.1.2. Email

R_US_2.1.3. Contraseña

R_US_2.2. El sistema validará que exista un usuario con el email y contraseña introducidos en la base de datos.

R_US_2.2.1. El sistema, en caso de no existir el usuario en la base de datos, mostrará un mensaje de error al usuario y no permitirá el inicio de sesión.

R_US_2.2.2. El sistema, en caso de si existir el usuario en la base de datos, permitirá acceder a la aplicación al usuario.

R_US_3. El sistema permitirá a los usuarios identificados salir de sesión.

5.3.1.2.3 *Procesamiento del texto*

R_TEXT_PROC_1. El sistema permitirá a los usuarios autenticados como profesores introducir texto.

R_TEXT_PROC_1.1. El sistema será capaz de procesar texto introducido directamente en un área.

R_TEXT_PROC_1.1.1. El sistema validará que el texto introducido no sea vacío.

R_TEXT_PROC_2. El sistema permitirá a los usuarios autenticados como profesores subir un fichero de texto.

R_TEXT_PROC_2.1. El sistema será capaz de procesar texto contenido en archivos txt.

R_TEXT_PROC_2.1.1. El sistema validará que el texto del archivo cargado no sea vacío.

R_TEXT_PROC_3. El sistema, en caso de ser tanto el texto introducido como el contenido del archivo de texto vacíos, no permitirá seguir con el procesamiento del texto.

R_TEXT_PROC_4. El sistema permitirá introducir un texto de prueba.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

5.3.1.2.4 *Gestión de palabras clave*

R_KEYWORDS_1. El sistema deberá ser capaz de, a partir del texto introducido (R_TEXT_PROC_1.), generar una lista de palabras clave.

R_KEYWORDS_2. El sistema permitirá editar la lista de palabras clave con las siguientes acciones:

R_KEYWORDS_2.1. Seleccionar todas las palabras clave.

R_KEYWORDS_2.1.1. El sistema, en caso de haber ya palabras seleccionadas, no modificará el contador de dichas palabras.

R_KEYWORDS_2.1.2. El sistema, en caso de haber palabras no seleccionadas, modificará su contador y lo pondrá a 1.

R_KEYWORDS_2.2. Deseleccionar todas las palabras clave.

R_KEYWORDS_2.2.1. El sistema, en caso de haber palabras seleccionadas, modificará su contador y lo pondrá a 0, independientemente de cuánto tuviese de antemano.

R_KEYWORDS_2.2.2. El sistema, en caso de haber ya palabras con el contador a 0, no modificará dicho contador.

R_KEYWORDS_2.3. Añadir una palabra clave.

R_KEYWORDS_2.3.1. El sistema validará que la nueva palabra no sea vacía.

R_KEYWORDS_2.3.2. El sistema validará que la nueva palabra no esté ya incluida en las sacadas por el propio sistema.

R_KEYWORDS_2.3.3. El sistema, en caso de que no se cumplan todas las validaciones, no permitirá añadir la nueva palabra clave.

R_KEYWORDS_2.4. Modificar el número de preguntas que se quieren generar a partir de una determinada palabra clave.

R_KEYWORDS_2.4.1. Aumentándolo.

R_KEYWORDS_2.4.1.1. El sistema, en caso de no aparecer dicha palabra las veces necesarias en el texto, permitirá aumentar la cifra igualmente.

R_KEYWORDS_2.4.2. Disminuyéndolo.

R_KEYWORDS_2.4.2.1. El sistema, en caso de estar ya en 0, no disminuirá más.

R_KEYWORDS_3. El sistema, en caso de intentar continuar sin haber seleccionado ninguna palabra clave, mostrará un mensaje de error y no permitirá continuar con la generación de preguntas.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

5.3.1.2.5 *Gestión de preguntas*

R_PREGUNTAS_1. El sistema generará preguntas partiendo del texto introducido y las palabras clave seleccionadas.

R_PREGUNTAS_2. El sistema permitirá editar cada una de las preguntas.

R_PREGUNTAS_2.1. El sistema permitirá cambiar el enunciado de la pregunta.

R_PREGUNTAS_2.1.1. El sistema validará que el enunciado no sea vacío.

R_PREGUNTAS_2.2. El sistema permitirá cambiar las opciones de la pregunta.

R_PREGUNTAS_2.2.1. El sistema validará que las opciones no sean vacías.

R_PREGUNTAS_2.2.2. El sistema validará que las opciones sean siempre cuatro.

R_PREGUNTAS_3. El sistema permitirá exportar las preguntas en los siguientes formatos.

R_PREGUNTAS_3.1. Archivos txt en formato Aiken.

R_PREGUNTAS_4. El sistema permitirá guardar el examen en la base de datos.

R_PREGUNTAS_5. El sistema generará como mínimo una pregunta por palabra clave seleccionada.

R_PREGUNTAS_5.1. El sistema evitará generar preguntas repetidas.

R_PREGUNTAS_6. El sistema generará como máximo el número de repeticiones seleccionado para cada palabra clave.

R_PREGUNTAS_6.1. El sistema generará tantas preguntas como repeticiones se hayan indicado para la palabra clave sin repetir.

R_PREGUNTAS_6.2. El sistema, en caso de no poder generar tantas preguntas para una palabra clave como pide el usuario, generará el máximo número posible sin repetir las preguntas.

R_PREGUNTAS_7. El sistema permitirá al usuario eliminar preguntas del examen.

5.3.1.2.6 *Búsqueda y realización de exámenes*

R_BUS_EX_1. El sistema permitirá a los usuarios identificados como estudiantes buscar exámenes en la aplicación.

R_BUS_EX_1.1. El sistema permitirá buscar un examen concreto mediante su id pública.

R_BUS_EX_1.2. El sistema, en caso de no encontrar un examen que se corresponda con la id buscada, mostrará un mensaje de error informando del problema.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

R_BUS_EX_1.3. El sistema, en caso de encontrar un examen con la id buscada por el usuario, mostrará el examen completo.

R_BUS_EX_2. El sistema permitirá realizar exámenes online.

R_BUS_EX_2.1. El sistema permitirá al usuario seleccionar una opción por pregunta del examen buscado por el mismo.

R_BUS_EX_2.2. El sistema permitirá al usuario comprobar sus respuestas.

R_BUS_EX_2.2.1. El sistema, en caso de comprobar una pregunta cuya respuesta sea correcta, mostrará un mensaje informando sobre el acierto.

R_BUS_EX_2.2.2. El sistema, en caso de comprobar una pregunta cuya respuesta sea incorrecta, mostrará un mensaje informando sobre el fallo.

R_BUS_EX_2.2.3. El sistema, en caso de comprobar una pregunta que no haya sido respondida, interpretará dicha respuesta en blanco como un fallo y mostrará un mensaje informando sobre el mismo.

R_BUS_EX_2.2.4. El sistema, en caso de comprobar una pregunta cuya respuesta sea incorrecta o en blanco, además del mensaje del fallo, indicará cuál era la respuesta correcta.

5.3.1.3 Atributos del sistema

5.3.1.3.1 *Requisitos de seguridad*

R_SEGURIDAD_1. La comunicación con el sistema se realizará vía HTTPS.

5.4 Especificación de Casos de Uso y Escenarios

5.4.1 Diagrama de contexto

A continuación, se muestra un diagrama de contexto que delimitará la funcionalidad del sistema a alto nivel.




Ilustración 5-1: Diagrama de contexto de la aplicación

5.4.2 Especificación de casos de uso

Además del diagrama de contexto, se indican las descripciones de casos de uso junto con sus diagramas correspondientes que detallan a más profundidad dicho diagrama de contexto. Por otra parte, se incluye trazabilidad con los requisitos mencionados (5.3.1.2.).

5.4.2.1 Ver página principal

Nombre del caso de uso:	Ver página principal
Quién lo inicia:	Usuario no identificado
Requisitos que satisface:	R_PAG_PRIN_1.
Descripción:	Solamente los usuarios no identificados verán la página principal de la aplicación. En esta página solamente se permiten realizar dos acciones, iniciar sesión o realizar registro.

Tabla 40: Caso de uso de ver la página principal

5.4.2.2 Gestión de usuarios

5.4.2.2.1 Registro de usuarios

Nombre del caso de uso:	Registro
Quién lo inicia:	Usuario no autenticado
Requisitos que satisface:	Requisitos incluidos en R_US_1.
Descripción:	
Cualquier usuario que previamente no se haya registrado de manera satisfactoria en la aplicación, podrá registrarse indicando se es profesor o estudiante, nombre, apellidos, email, contraseña y repetición de contraseña. El sistema validará los datos introducidos. Si alguna validación falla, se mostrará un mensaje informando al usuario de qué ha ido mal. En caso de cumplir todas las validaciones, el usuario podrá entrar a la aplicación a la vista correspondiente, en función de si es estudiante (buscar exámenes por id pública) o profesor (procesamiento de texto).	

Tabla 41: Caso de uso de registro de usuarios

5.4.2.2.2 Inicio de sesión de usuarios

Nombre del caso de uso:	Iniciar sesión
Quién lo inicia:	Usuario no identificado
Requisitos que satisface:	Requisitos incluidos en R_US_2.
Descripción:	
Cualquier usuario que previamente se haya registrado de manera satisfactoria en la aplicación, podrá iniciar sesión con su usuario y contraseña, indicando si es profesor o estudiante. El sistema comprobará que el email junto con la contraseña introducidos haya sido previamente registrado, es decir, estén en la base de datos. En caso de que así sea, el usuario será redirigido a la sección correspondiente en función de si es estudiante (buscar exámenes por id pública) o profesor (procesamiento de texto). En caso de no ser así, se mostrará un mensaje que impedirá al usuario iniciar sesión.	

Tabla 42: Caso de uso de inicio de sesión de usuarios

5.4.2.2.3 *Salir de sesión*

Nombre del caso de uso:	Salir de sesión
Quién lo inicia:	Usuario identificado
Requisitos que satisface:	R_US_3.
Descripción:	
Cualquier usuario que previamente se haya identificado y esté dentro de la aplicación, podrá salir de la misma y volverá a la vista de la página principal, donde únicamente se permite iniciar sesión o registrarse.	

Tabla 43: Caso de uso de salir de sesión de usuarios

5.4.2.3 Procesamiento de texto




Ilustración 5-2: Diagrama de casos de uso de procesamiento de texto

5.4.2.3.1 *Escritura de texto en un área*

Nombre del caso de uso:	Escritura de texto
Quién lo inicia:	Usuario identificado como profesor
Requisitos que satisface:	Requisitos incluidos en R_TEXT_PROC_1. Y R_TEXT_PROC_3.
Descripción:	

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

Cualquier usuario que previamente se haya identificado como profesor, podrá introducir texto en un área para su posterior procesamiento. Dicho texto, para que el sistema funcione correctamente, debe estar en inglés.

En caso de que el contenido del área de texto sea vacío, el sistema no permitirá al usuario continuar con el procesamiento. En caso contrario, el sistema comenzará su procesado para sacar las palabras clave.

Tabla 44: Caso de uso de introducir texto en área para procesamiento

5.4.2.3.2 *Subida de ficheros de texto*

Nombre del caso de uso:	Subida de archivos de texto
Quién lo inicia:	Usuario identificado como profesor
Requisitos que satisface:	Requisitos incluidos en R_TEXT_PROC_2. y R_TEXT_PROC_3.
Descripción:	
Cualquier usuario que previamente se haya identificado como profesor, podrá cargar un archivo de texto para su posterior procesamiento. Dicho archivo, para que el sistema funcione correctamente, debe estar en inglés.	
En caso de que el contenido del fichero de texto sea vacío, el sistema no permitirá al usuario continuar con el procesamiento. En caso contrario, el sistema comenzará su procesado para sacar las palabras clave.	

Tabla 45: Caso de uso de subir archivo de texto para procesamiento

5.4.2.3.3 *Carga de texto de prueba*

Nombre del caso de uso:	Carga de texto de prueba
Quién lo inicia:	Usuario identificado como profesor
Requisitos que satisface:	Requisitos incluidos en R_TEXT_PROC_4.
Descripción:	

Cualquier usuario que previamente se haya identificado como profesor, podrá cargar un texto de prueba para su posterior procesamiento. Dicho texto, para que el sistema funcione correctamente, está en inglés.

Tabla 46: Caso de uso de cargar texto de prueba para procesamiento

5.4.2.4 Gestión de palabras clave




Ilustración 5-3: Diagrama de casos de uso de gestión de palabras clave

5.4.2.4.1 Vista de palabras clave generadas

Nombre del caso de uso:	Vista de palabras clave
Quién lo inicia:	Usuario identificado como profesor
Requisitos que satisface:	R_KEYWORDS_1.
Descripción:	Cualquier usuario que previamente se haya identificado como profesor, podrá observar las palabras clave que muestra el sistema una vez haya sido procesado el texto del apartado anterior.

Tabla 47: Caso de uso de ver las palabras clave

5.4.2.4.2 *Seleccionar palabras clave*

Nombre del caso de uso:	Seleccionar todas las palabras clave
Quién lo inicia:	Usuario identificado como profesor
Requisitos que satisface:	Requisitos incluidos en R_KEYWORDS_2.1. y R_KEYWORDS_3.
Descripción:	
Cualquier usuario que previamente se haya identificado como profesor, podrá seleccionar directamente todas las palabras mostradas para la posterior generación de preguntas.	

Tabla 48: Caso de uso de seleccionar todas las palabras clave

5.4.2.4.3 *Deseleccionar palabras clave*

Nombre del caso de uso:	Deseleccionar todas las palabras clave
Quién lo inicia:	Usuario identificado como profesor
Requisitos que satisface:	Requisitos incluidos en R_KEYWORDS_2.2. y R_KEYWORDS_3.
Descripción:	
Cualquier usuario que previamente se haya identificado como profesor, podrá deseleccionar directamente todas las palabras mostradas.	

Tabla 49: Caso de uso de deseleccionar todas las palabras clave

5.4.2.4.4 *Añadir palabras clave*

Nombre del caso de uso:	Adición de palabras clave
Quién lo inicia:	Usuario identificado como profesor
Requisitos que satisface:	Requisitos incluidos en R_KEYWORDS_2.3.
Descripción:	

Cualquier usuario que previamente se haya identificado como profesor, podrá añadir palabras clave a la lista generada por el sistema, posteriormente, si la palabra añadida no se encuentra en el texto procesado, el sistema no mostrará ninguna pregunta referente a dicha palabra.

Tabla 50: Caso de uso de añadir una palabra clave

5.4.2.4.5 *Modificar número de preguntas a generar*

Nombre del caso de uso:	Modificación del número de preguntas a generar para cada palabra clave
Quién lo inicia:	Usuario identificado como profesor
Requisitos que satisface:	Requisitos incluidos en R_KEYWORDS_2.4.
Descripción:	
Cualquier usuario que previamente se haya identificado como profesor, podrá modificar el contador asignado a cada palabra clave, el cual representa el número de preguntas que se generarán a partir de dicha palabra.	

Tabla 51: Caso de uso de modificar el número de preguntas por palabra clave

5.4.2.5 Gestión de preguntas




Ilustración 5-4: Diagrama de casos de uso de gestión de preguntas

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO
			JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es

5.4.2.5.1 *Vista de preguntas generadas*

Nombre del caso de uso:	Vista de preguntas
Quién lo inicia:	Usuario identificado como profesor
Requisitos que satisface:	R_PREGUNTAS_1.
Descripción:	
Cualquier usuario que previamente se haya identificado como profesor, podrá ver las preguntas generadas por el sistema a partir de las palabras clave seleccionadas en el apartado anterior.	

Tabla 52: Caso de uso de vista de preguntas

5.4.2.5.2 *Generación de preguntas por palabra clave*

Nombre del caso de uso:	Generación de preguntas por palabra clave
Quién lo inicia:	Usuario identificado como profesor
Requisitos que satisface:	Requisitos incluidos en R_PREGUNTAS_5. Y R_PREGUNTAS_6.
Descripción:	
Cualquier usuario que previamente se haya identificado como profesor, podrá generar preguntas a partir de las palabras clave seleccionadas, el sistema generará como mínimo una pregunta por palabra seleccionada (en caso de ser una palabra añadida a mano puede no generarse ninguna) y como máximo tantas como se haya seleccionado, siempre y cuando la palabra se repita las suficientes veces en el texto, en cuyo caso éste pasará a ser el máximo.	

Tabla 53: Caso de uso de generación de preguntas por palabra clave

5.4.2.5.3 *Editar enunciado de cada pregunta*

Nombre del caso de uso:	Edición del enunciado de las preguntas
Quién lo inicia:	Usuario identificado como profesor
Requisitos que satisface:	Requisitos incluidos en R_PREGUNTAS_2.1.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO
			JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es

Descripción:
Cualquier usuario que previamente se haya identificado como profesor, podrá editar el enunciado de cada pregunta.

Tabla 54: Caso de uso de edición del enunciado de las preguntas

5.4.2.5.4 *Editar opciones de cada pregunta*

Nombre del caso de uso:	Edición de las opciones de las preguntas
Quién lo inicia:	Usuario identificado como profesor
Requisitos que satisface:	Requisitos incluidos en R_PREGUNTAS_2.2.
Descripción:	
Cualquier usuario que previamente se haya identificado como profesor, podrá editar las opciones de cada pregunta.	

Tabla 55: Caso de uso de edición de las opciones de las preguntas

5.4.2.5.5 *Eliminar preguntas*

Nombre del caso de uso:	Eliminación de preguntas
Quién lo inicia:	Usuario identificado como profesor
Requisitos que satisface:	R_PREGUNTAS_7.
Descripción:	
Cualquier usuario que previamente se haya identificado como profesor, podrá eliminar preguntas del examen.	

Tabla 56: Caso de uso de eliminación de preguntas

5.4.2.5.6 *Exportación de preguntas*

Nombre del caso de uso:	Exportación de preguntas
Quién lo inicia:	Usuario identificado como profesor

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	--

Requisitos que satisface:	Requisitos incluidos en R_PREGUNTAS_3.
Descripción:	
Cualquier usuario que previamente se haya identificado como profesor, podrá exportar las preguntas del examen y descargar un archivo txt en formato Aiken.	

Tabla 57: Caso de uso de exportación de preguntas

5.4.2.5.7 *Guardado de examen*

Nombre del caso de uso:	Guardado de preguntas
Quién lo inicia:	Usuario identificado como profesor
Requisitos que satisface:	R_PREGUNTAS_4.
Descripción:	
Cualquier usuario que previamente se haya identificado como profesor, podrá guardar las preguntas del examen en la base de datos para que usuarios estudiantes puedan acceder a ellos.	

Tabla 58: Caso de uso de guardado de preguntas

5.4.2.6 Búsqueda y realización de exámenes




Ilustración 5-5: Diagrama de casos de uso de búsqueda y realización de exámenes

5.4.2.6.1 *Búsqueda de exámenes*

Nombre del caso de uso:	Búsqueda de exámenes
Quién lo inicia:	Usuario identificado como estudiante
Requisitos que satisface:	Requisitos incluidos en R_BUS_EX_1.
Descripción:	
Cualquier usuario que previamente se haya identificado como estudiante, podrá buscar exámenes por su id pública.	

Tabla 59: Caso de uso de búsqueda de exámenes

5.4.2.6.2 *Realización de exámenes*

Nombre del caso de uso:	Realización de exámenes
Quién lo inicia:	Usuario identificado como estudiante
Requisitos que satisface:	Requisitos incluidos en R_BUS_EX_2.
Descripción:	
Cualquier usuario que previamente se haya identificado como estudiante, podrá realizar un examen que haya buscado y comprobar sus resultados.	

Tabla 60: Caso de uso de realización de exámenes

5.5 *Identificación de subsistemas a nivel de arquitectura de la aplicación*

En este apartado se expondrán los subsistemas que forman el sistema, exponiendo la estructura general del mismo.




Ilustración 5-6: Subsistemas de arquitectura simplificado

5.5.1 Descripción de los subsistemas a nivel de arquitectura

Se describen a continuación los subsistemas identificados en la figura anterior:

- **Webapp:** Lo forman todos los componentes de la interfaz de usuario. Este será el punto de interacción con el usuario.
- **Restapi:** Contiene la infraestructura de comunicación con la base de datos, encargándose así de suministrar los datos que la interfaz necesite en cada momento. Además, incluye el algoritmo de extracción de palabras clave, así como el de generación de preguntas a partir de dichas palabras.

La comunicación entre Webapp y Restapi se realizará a través de peticiones HTTPS, de manera que permita tener ambos en máquinas diferentes. La Restapi, enviará sus datos hacia la interfaz en formato JSON (Java Script Object Notation).

5.6 Definición de Interfaces de Usuario

En este apartado se mostrarán esquemas representativos de las pantallas de la interfaz de usuario, de manera que se pueda identificar la disposición general de los elementos que contiene la aplicación.

5.6.1 Pantalla de inicio

En esta vista solamente se puede acceder a los formularios de inicio de sesión o de registro.





Ilustración 5-7: Boceto de la pantalla de inicio

5.6.2 Pantalla de inicio de sesión

Esta vista permite identificar a los usuarios que ya han sido registrados previamente. Necesitarán indicar el tipo de usuario que quiere identificarse, el email y la contraseña. Una vez hayan accedido, cada usuario podrá realizar las acciones pertinentes, búsqueda de exámenes por parte de los estudiantes y realización de los mismos. En el caso de los profesores, podrán crearlos a partir de textos.



Login

HistKey

User Type: ☐ Teacher ☐ Student

Email:

Password:

Login

Ilustración 5-8: Boceto de la pantalla de inicio de sesión

5.6.3 Pantalla de registro de usuario

En esta otra vista es donde los usuarios pasan a estar registrados en la aplicación y sus datos se guardan en la base de datos. Una vez se haya registrado, no necesitará pasar por el login para acceder a la aplicación, podrá realizar las mismas acciones como si hubiese iniciado sesión desde el login.





Ilustración 5-9: Boceto de la pantalla de registro de sesión

5.6.4 Pantalla de carga del texto

Esta pantalla contiene las diferentes vías de cargar el texto a procesar en la aplicación, ya sea mediante subida de fichero de texto o copia del mismo en el área. Además, da la opción de cargar un texto de prueba.



Text

HistKey

Upload txt file

Copy text here...

Use demo text

Search Keywords

Ilustración 5-10: Boceto de la pantalla de carga del texto

5.6.5 Pantalla de palabras clave

Esta pantalla contiene la gestión de las palabras clave, en ella se puede seleccionar las palabras de las cuales se quiere generar pregunta, además, contiene ayudas para seleccionar todas o deseleccionar todas en caso de ser necesario. También permite añadir nuevas palabras clave que se consideren importantes.




Ilustración 5-11: Boceto de la pantalla de gestión de palabras clave

5.6.6 Pantalla de gestión de preguntas

En esta pantalla se podrá gestionar las preguntas, es decir, modificar pregunta (tanto enunciado como opciones), eliminar pregunta, guardar el examen generado, descargarlo y finalizar el proceso de generación de preguntas.




Ilustración 5-12: Boceto de la pantalla de gestión de preguntas

5.6.7 Pantalla de búsqueda de exámenes

En esta pantalla solamente se puede realizar una función, buscar un examen guardado previamente por algún usuario profesor, mediante la id pública asignada por este último.




Ilustración 5-13: Boceto de la pantalla de búsqueda de exámenes

5.6.8 Pantalla de resolución de examen

En esta pantalla, un usuario estudiante podrá resolver el examen buscado, así como comprobar si sus respuestas son correctas.




Ilustración 5-14: Boceto de la pantalla de resolución de examen

5.6.9 Diagrama de navegabilidad

En este apartado se muestra esquemáticamente la manera de navegar de unas pantallas a otras del sistema, dejando claro cuál es el flujo de pantallas.




Ilustración 5-15: Diagrama de navegabilidad del sistema

6 Diseño del Sistema de Información

6.1 Diseño Físico de datos

6.1.1 Descripción del SGBD utilizado

Para el desarrollo del proyecto se ha usado un Sistema de Gestión de Bases de Datos (SGBD) NoSQL, concretamente MongoDB. Este SGBD es una de las opciones más populares para el almacenamiento y gestión de datos en aplicaciones modernas.

MongoDB surgió en 2007, aunque públicamente se lanzara en 2009, con el objetivo de proporcionar una respuesta a las limitaciones percibidas de las bases de datos relacionales tradicionales en cuanto a escalabilidad y flexibilidad en la gestión de dato no estructurados o semiestructurados.

6.1.2 Integración del SGBD en el sistema

La integración del Sistema de Gestión de Bases de Datos en la aplicación se hizo mediante la biblioteca de modelado de objetos para MongoDB, Mongoose, la cual es un complemento para Node.js que facilita notablemente la interacción con bases de datos MongoDB desde aplicaciones Node.js. Proporciona una capa de abstracción sobre la base de datos MongoDB, lo que simplifica y agiliza el desarrollo de aplicaciones que usan este SGBD como sistema de almacenamiento de datos.

6.2 Diseño de la API REST

En este apartado se explicarán el diseño de las rutas de la Restapi, agrupadas por funciones.

6.2.1 Procesamiento del texto

6.2.1.1 Cargar texto de prueba

- **Ruta:** /read-demo-file/
- **Método HTTP:** GET
- **Parámetros:**
- **Retorno:** texto de prueba

6.2.2 Keywords

6.2.2.1 Búsqueda de palabras clave

- **Ruta:** /keywords/
- **Método HTTP:** POST
- **Parámetros:**

```
{
  theText: text
}
```

- **Retorno:** palabras clave del texto pasado en el body

6.2.3 Preguntas

6.2.3.1 Generación de preguntas

- **Ruta:** /questions/
- **Método HTTP:** POST
- **Parámetros:**

```
{
  theText: text,
  keywords: Array.from(keysMap.keys()),
  repetitions: Array.from(keysMap.values())
}
```

- **Retorno:** conjunto de preguntas en las que la palabra clave ha sido sustituida por '_____'. Incluye también las opciones de respuesta a la pregunta.

6.2.4 Usuarios

6.2.4.1 Inicio de sesión profesor

- **Ruta:** /teacher/
- **Método HTTP:** GET
- **Parámetros:**

```
/teacher?email=${formEmail}&pass=${password}
```

- **Retorno:** devuelve el usuario profesor con dicho email, siempre y cuando la contraseña también coincida. En caso de no existir, devuelve null.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

6.2.4.2 Inicio de sesión estudiante

- **Ruta:** /student/
- **Método HTTP:** GET
- **Parámetros:**
`/student?email=${formEmail}&pass=${password}`
- **Retorno:** devuelve el usuario estudiante con dicho email, siempre y cuando la contraseña también coincida. En caso de no existir, devuelve null.

6.2.4.3 Registro de usuario

- **Ruta:** /user/
- **Método HTTP:** POST
- **Parámetros:**

```
{
  type: user,
  name: formName,
  surname: formSurname,
  email: formEmail,
  pass: password
}
```
- **Retorno:** devuelve el usuario recién insertado.

6.2.4.4 Borrado de profesor (para Testing)

- **Ruta:** /teacher/:email
- **Método HTTP:** DELETE
- **Parámetros:**
`/teacher/${email}`
- **Retorno:** devuelve true si lo elimina y null en caso contrario

6.2.4.5 Borrado de estudiante (para Testing)

- **Ruta:** /student/:email
- **Método HTTP:** DELETE
- **Parámetros:**
`/student/${email}`
- **Retorno:** devuelve true si lo elimina y null en caso contrario

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

6.2.5 Exámenes

6.2.5.1 Guardar examen

- **Ruta:** /exam/
- **Método HTTP:** POST
- **Parámetros:**

```
{
  public_id: id,
  questions: contenidoTexto
}
```

- **Retorno:** el examen recién creado y guardado en la base de datos.

6.2.5.2 Obtener examen

- **Ruta:** /exam/:id
- **Método HTTP:** GET
- **Parámetros:**

```
/exam/${p_id}
```

- **Retorno:** el examen que coincida con la id pública pasada por parámetro.

6.2.5.3 Borrado de examen (para Testing)

- **Ruta:** /exam/:id
- **Método HTTP:** DELETE
- **Parámetros:**

```
/exam/${publicId}
```

- **Retorno:** devuelve true si lo elimina y null en caso contrario

6.3 Diagrama de despliegue




Ilustración 6-6-1: Diagrama de despliegue del sistema

La Restapi de la aplicación está desplegada con Render, sin embargo, la Webapp, está desplegada en gh-pages. De esta manera al ejecutar el Frontend de la aplicación, este se comunicará con el backend desplegado en render para obtener los datos que sean requeridos por el usuario que esté usando la aplicación.

A su vez, el backend se comunicará con la base de datos NoSQL MongoDB para obtener los datos allí alojados que sean necesarios en cada momento.

La aplicación está pensada para interactuar con la Webapp, sin embargo, al estar también desplegado el backend, es posible realizar peticiones directamente si lo que se desea es usar los servicios de búsqueda de palabras clave o generación de preguntas y no la aplicación entera.

6.4 Diseño del Plan de Pruebas

Para entender mejor las pruebas realizadas, se comentará en este apartado los aspectos más importantes.

6.4.1 Pruebas de la Restapi

En las pruebas hay documentación acerca de qué se está probando en cada test, sin embargo, aquí se dará una visión general.

6.4.1.1 Pruebas de usuarios

En las pruebas de usuarios, se prueban 3 endpoints distintos, el de estudiantes, profesores y el de usuarios (más genérico). Las pruebas realizadas sobre los de profesores y estudiantes son similares y cubren los siguientes puntos clave:

- Buscar un profesor existente en la base de datos (GET)
- Intentar buscar un profesor no existente en la base de datos (GET)

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

- Eliminar un profesor existente en la base de datos (DELETE)
- Intentar eliminar un profesor no existente en la base de datos (DELETE)
- Buscar un estudiante existente en la base de datos (GET)
- Intentar buscar un estudiante no existente en la base de datos (GET)
- Eliminar un estudiante existente en la base de datos (DELETE)
- Intentar eliminar un estudiante no existente en la base de datos (DELETE)

En cuanto al endpoint de usuarios se probaron los siguientes aspectos:

- Añadir un usuario profesor nuevo (POST)
- Intentar añadir un usuario profesor ya existente (POST)
- Añadir un usuario estudiante nuevo (POST)
- Intentar añadir un usuario estudiante ya existente (POST)

6.4.1.2 Pruebas del texto

En este apartado de las pruebas se trató de probar la carga del texto de demo:

- Obtener el texto de demo (GET)

6.4.1.3 Pruebas de palabras clave

En cuanto a la obtención de palabras clave, se probó con un texto operativo y con un texto vacío:

- Obtener palabras clave de un texto operativo (POST)
- Intentar obtener palabras clave de un texto vacío (POST)

6.4.1.4 Pruebas de preguntas

Los aspectos críticos probados en cuanto a las preguntas fueron los siguientes:

- Obtener preguntas con todos los parámetros correctos (POST)
- Intentar obtener preguntas a partir de una palabra que no aparece en el texto (POST)
- Intentar obtener más preguntas que las apariciones de la palabra clave (POST)
- Intentar obtener preguntas de un texto vacío (POST)

6.4.1.5 Pruebas con exámenes

Finalmente, las pruebas con exámenes fueron llevadas a cabo basándose en los siguientes aspectos:

- Añadir un examen nuevo (POST)

Capítulo 6. Diseño del Sistema de Información	Versión 1.0.0	Hoja 98 de 134
---	---------------	----------------

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	--

- Intentar añadir un examen con id pública repetida (POST)
- Buscar un examen por su id pública (GET)
- Intentar buscar un examen por una ide pública que no existe (GET)
- Eliminar un examen por su id pública (DELETE)
- Intentar eliminar un examen no existente (DELETE)

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

7 Implementación del Sistema de Información

7.1 Lenguajes de programación

A continuación, se enumeran los lenguajes de programación usados en el desarrollo del proyecto:

7.1.1 JavaScript

JavaScript es un lenguaje de programación ampliamente utilizado en el desarrollo web y, en los últimos años, ha encontrado aplicaciones en otros entornos además de los navegadores web.

Es un lenguaje de programación versátil que se usa tanto del lado del cliente como del lado del servidor, de esta manera fue utilizado en el proyecto, del lado del cliente desarrollando la Webapp ayudándose de la biblioteca React y del lado del servidor, en un entorno Node.js construyendo la Restapi.

7.2 Herramientas usadas para el desarrollo

7.2.1 Visual Studio Code



Visual Studio Code es un editor de código de gran calidad y versatilidad que se ha convertido en una opción popular entre los desarrolladores debido a su potencia, flexibilidad y la amplia gama de extensiones disponibles. Es una herramienta muy útil para el desarrollo de software en múltiples plataformas y lenguajes de programación.

- **Versión utilizada:** 1.84.2
- **Última versión:** 1.84
- **Desarrollador:** Microsoft
- **Sitio:** <https://code.visualstudio.com/>

7.2.2 Mozilla Firefox

Para visualizar los resultados y cambios que se iban obteniendo, así como depurar la aplicación por medio de las opciones de desarrollador, fue usado Mozilla Firefox.

- **Versión utilizada:** 119.01
- **Última versión:** 119
- **Desarrollador:** Fundación Mozilla
- **Sitio:** <https://www.mozilla.org/>

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO
			JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es

7.2.3 Git

Git es un sistema de control de versiones ampliamente utilizado en el desarrollo de software. Es fundamental para el seguimiento de cambios en el código fuente y la gestión del historial de versiones, también tiene otra clara ventaja que en este caso no aplica debido a que es un proyecto individual y no grupal, sin embargo, Git facilita en gran medida la colaboración en proyectos de software.

- **Versión utilizada:** 2.35.1
- **Última versión:** 2.42.0
- **Desarrollador:** Linus Torvalds
- **Sitio:** <https://git-scm.com/>

7.2.3.1 GitHub

GitHub es una plataforma en línea que ofrece servicios de alojamiento de repositorios de Git.

- **Desarrollador:** Tom Preston-Werner Chris Wanstrath PJ Hyett
- **Sitio:** <https://github.com/>
- **Mi perfil de GitHub:** <https://github.com/jorge16lp>

8 Ejecución de las Pruebas

8.1 Pruebas de la Restapi

La ejecución de las pruebas de los endpoints de la Restapi fueron los siguientes:

```

PS C:\Users\Jorge\Downloads\TFG\algoritmos_final\restapi> npm test
> algoritmos@1.0.0 test
> mocha ./tests/*

API REST corriendo en http://localhost:3001
API REST corriendo en https://histkey-restapi.onrender.com

Test de endpoint /exam/
✓ AÑADIR EXAMEN CORRECTO: debería agregar el examen correctamente (831ms)
✓ AÑADIR EXAMEN YA EXISTENTE: debería no agregar el examen (85ms)
✓ BUSCAR EXAMEN EXISTENTE: debería devolver el examen correctamente (124ms)
✓ BUSCAR EXAMEN NO EXISTENTE: debería devolver null (80ms)
✓ ELIMINAR EXAMEN EXISTENTE: debería devolver true (63ms)
✓ ELIMINAR EXAMEN NO EXISTENTE: debería devolver null (58ms)

Test de endpoint /keywords/
✓ TEXTO PROBADO: Debería devolver 21 palabras clave correctamente (605ms)
✓ TEXTO VACÍO: Debería devolver 0 palabras clave

Test de endpoint /questions/
✓ TEXTO, PALABRAS Y REPETICIONES CORRECTOS: genera tantas preguntas como se le pide
✓ PALABRA QUE NO EXISTE: no genera preguntas cuando la palabra no sale en el texto
✓ MÁS REPETICIONES QUE APARICIONES: genera el máximo nº de preguntas posible sin repetirlas (64ms)
✓ TEXTO VACÍO: no genera preguntas

Test de endpoint /read-demo-file/
✓ TEXTO DE DEMO: Debería devolver el texto correctamente

Test de endpoint /teacher/
✓ BUSCAR PROFESOR EXISTENTE: debería devolver el usuario del profesor correctamente (40ms)
✓ BUSCAR PROFESOR NO EXISTENTE: debería devolver null (40ms)
✓ BUSCAR PROFESOR NO COINCIDEN EMAIL Y PASSWORD: debería devolver null (43ms)
✓ ELIMINAR PROFESOR EXISTENTE: debería devolver true (53ms)
✓ ELIMINAR PROFESOR NO EXISTENTE: debería devolver null (44ms)

Test de endpoint /student/
✓ BUSCAR ESTUDIANTE EXISTENTE: debería devolver el usuario del estudiante correctamente (49ms)
✓ BUSCAR ESTUDIANTE NO EXISTENTE: debería devolver null
✓ BUSCAR ESTUDIANTE NO COINCIDEN EMAIL Y PASSWORD: debería devolver null (48ms)
✓ ELIMINAR ESTUDIANTE EXISTENTE: debería devolver true (70ms)
✓ ELIMINAR ESTUDIANTE NO EXISTENTE: debería devolver null (63ms)

Test de endpoint /user/
✓ AÑADIR USUARIO PROFESOR CORRECTO: debería agregar un usuario teacher correctamente (55ms)
✓ AÑADIR USUARIO PROFESOR YA EXISTENTE: debería no agregar al usuario teacher (44ms)
✓ AÑADIR USUARIO ESTUDIANTE CORRECTO: debería agregar un usuario student correctamente (50ms)
✓ AÑADIR USUARIO ESTUDIANTE YA EXISTENTE: debería no agregar al usuario student (43ms)

27 passing (3s)

```

Ilustración 8-1: Ejecución de las pruebas de la Restapi

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

Las pruebas fueron llevadas a cabo mediante Mocha, el cual es un marco de pruebas (Testing framework) para JavaScript que sirve tanto para el entorno de navegador, como para Node.js. Con Mocha se pueden definir pruebas de manera flexible. La estructura es sencilla, por ejemplo:

```
describe('Test de endpoint /read-demo-file/', () => {
  it('TEXTO DE DEMO: Debería devolver el texto', (done) => {
    supertest(app)
      .get('/read-demo-file/')
      .expect(200)
      .end((err, res) => {
        if (err) return done(err)

        // la respuesta debería ser un objeto con la propiedad 'demoText'
        assert.strictEqual(typeof res.body, 'object')
        assert.ok(res.body.demoText)

        done()
      })
  })
})
```

Para este caso concreto del test de carga del texto de demo, se estaría ejecutando el caso con una petición GET a la ruta ‘/read-demo-file/’, esperando un código de estado 200, lo cual quiere decir que la petición fue exitosa y posteriormente se realizar comprobaciones sobre el retorno de dicho endpoint. Esta estructura, pero ajustada a los casos particulares, es la que se repite en todos los casos de prueba de la Restapi.

9 Manuales de Usuario

9.1 Manual para el desarrollador

9.1.1 Descargar el código de la Webapp

Hay dos opciones para descargar dicho código fuente:

1. Descargar Git y clonar el repositorio de GitHub que contiene dicho código con el siguiente comando:

```
git clone https://github.com/jorge16lp/Histkey_webapp.git
```

2. Descargar el archivo comprimido con todo el código directamente desde GitHub (https://github.com/jorge16lp/Histkey_webapp):




Ilustración 9-1: Descarga del fichero comprimido de la Webapp de GitHub

9.1.2 Descargar el código de la Restapi

De igual manera, tenemos las dos mismas opciones:

1. Descargar Git y clonar el repositorio de GitHub que en este caso contiene el código fuente de la Restapi con el siguiente comando:

```
git clone https://github.com/jorge16lp/Histkey_restapi.git
```

2. Descargar el archivo comprimido con todo el código directamente desde GitHub (https://github.com/jorge16lp/Histkey_restapi):




Ilustración 9-2: Descarga del fichero comprimido de la Restapi de GitHub

9.1.3 Instalación de la Restapi

En primer lugar, para instalar el backend de la aplicación, es necesario tener instalado Node.js. Este proyecto se ha llevado a cabo usando la versión de Node 18.16.0, sin embargo, es posible instalar la última versión LTS (del inglés, Long Term Support) que hay actualmente, esto dignifica que tiene soporte por un periodo de 18 meses. La última versión LTS es la 20.9.0 y se puede descargar en <https://nodejs.org/en/download/>.




Ilustración 9-3: Descarga de la última versión LTS de Node.js

Una vez hacemos clic en el instalador, se descargará directamente y podremos ejecutarlo con doble clic. Siguiendo todas las instrucciones del instalador conseguiremos tener Node instalado. Podemos comprobar la correcta instalación ejecutando los siguientes comandos y observando como devuelven la versión instalada:

```
node --version
npm --version
```

Para manejar los paquetes de Node usaremos un gestor de paquetes, sin embargo, no es necesario instalar ninguno porque al instalar Node.js ya tenemos NPM (Node Package Manager) instalado.

Una vez tengamos el código descargado y Node.js instalado con su gestor de paquetes, podremos ejecutarlo, sin embargo, primero necesitaremos instalar las dependencias del proyecto para lo cual nos situaremos en la carpeta principal del proyecto y ejecutaremos el siguiente comando:

```
npm install
```

Con este comando se instalarán todas las dependencias que la Restapi requiera para su correcto funcionamiento. Una vez se hayan instalado, en el mismo directorio en el que estamos (carpeta principal del backend), ejecutamos con Node el fichero JavaScript principal, en este caso llamado index.js de la siguiente manera:

```
node index.js
```

De esta manera tendremos el backend ejecutándose en la dirección <http://localhost:3001>.

Otra manera de ejecutar el backend es utilizando el siguiente comando:

```
npm start
```

Al ejecutar este comando, el gestor de paquetes busca el comando asignado a la instrucción ‘start’, el cual es “node index.js” y se ejecuta la aplicación.

Una última manera de poner en ejecución la Restapi es mediante el siguiente comando:

```
npm run dev
```

De esta manera se está buscando, de igual manera que antes se buscaba el asociado a ‘start’, el comando asociado a ‘dev’, que en este caso es “nodemon index.js”. Dicho comando permite tener ejecutándose el backend y realizar cambios en él a la vez, de manera que, al guardar dichos cambios, todo el backend se actualice sin tener que relanzar la aplicación.

9.1.4 Instalación de la Webapp

El Frontend de la aplicación se ha realizado usando JavaScript con la biblioteca React, la cual hay que instalarla mediante el gestor de paquetes de Node comentado en el apartado anterior (9.1.3), para ello debemos tener instalado Node.js siguiendo los pasos que indica en dicho apartado.

Una vez se haya instalado Node correctamente y comprobado que está operativo en el sistema, hay que instalar las dependencias, de igual manera que en el caso del backend, ejecutaremos el siguiente comando:

```
npm install
```

Tras ejecutar este comando, tendremos React, y el resto de dependencias, instalado y listo para ejecutar la aplicación del Frontend. El último paso sería ejecutar el script de inicio:

```
npm start
```

Con dicho script se ejecuta el comando “react-scripts start”, lo cual arranca la aplicación en la dirección http://localhost:3000/Histkey_webapp.

9.2 Manual de usuario

9.2.1 Acceso al sistema

Para acceder a la aplicación hay dos caminos, el primero es ejecutar el proyecto de manera local en nuestra máquina, para ello es necesario instalar el proyecto y seguir los pasos del apartado 9.1.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	--

El otro camino, más sencillo, es acceder a la dirección de despliegue de la aplicación, donde se puede ejecutar la aplicación sin necesidad de realizar instalaciones. Dichas direcciones son las siguientes:

- Dirección de despliegue del Frontend (**Webapp**):

https://jorge16lp.github.io/Histkey_webapp/

- Dirección de despliegue del backend (**Restapi**):

<https://histkey-restapi.onrender.com/>

9.2.2 Autenticación de usuario

En la aplicación es posible tanto iniciar sesión como registrarse si se es un usuario nuevo. Ambas opciones aparecen en el centro de la página de inicio, ya que, sin identificarse, no es posible realizar ninguna función en la aplicación.




Ilustración 9-4: Acceso a registro e inicio de sesión

En caso de querer iniciar sesión, se solicita introducir email y contraseña, además de marcar que tipo de usuario eres, estudiante o profesor. Dicho formulario de inicio de sesión se encuentra en la ruta '/login':





Ilustración 9-5: Formulario de inicio de sesión

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO
			JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es

Para el registro es necesario la introducción de más datos además del email y la contraseña, en concreto, nombre, apellido y repetición de contraseña por si el usuario se equivoca al escribirla la primera vez. Corresponde dicho formulario a la ruta '/signup':



Here you can sign up the application

User type: ☒ Teacher ☐ Student

Name:

Surname:

Email:

Password:

Repeat password:

Ilustración 9-6: Formulario de registro

Una vez un usuario accede a la aplicación, es redirigido a la pantalla correspondiente en función de si es un usuario profesor o un usuario estudiante, en el primer caso accederá a la creación de exámenes, en el segundo a la búsqueda de los mismos.

9.2.3 Procesamiento de textos

Los usuarios que previamente hayan sido identificados como profesores tendrán la opción de generar exámenes, y el primer paso de dicho proceso es el procesamiento de un texto. Para procesar dicho texto, el usuario profesor podrá subir un archivo de texto o copiar el contenido directamente en el área indicada para ello. La ruta que contiene dicho procesamiento del texto es '/text':



Ilustración 9-7: Procesamiento de texto

Tiene el profesor la posibilidad de utilizar un texto de prueba si lo que quiere es ver el funcionamiento de la aplicación y comprobar si sabe utilizarla.

9.2.4 Gestión de palabras clave

Una vez se haya procesado el texto, el resultado será un conjunto de palabras clave sacadas del mismo. Se mostrarán de la siguiente manera en la ruta '/keywords':




Ilustración 9-8: Vista de las palabras clave extraídas del texto

Las palabras clave se muestran en orden alfabético para que sea más sencillo buscar alguna palabra determinada.

Por defecto no habrá ninguna seleccionada, pero se tiene acceso a dos botones para seleccionar o deseleccionar todas las palabras mostradas.

Además, en la parte inferior hay una sección en la cual se le permite al usuario añadir alguna palabra que considere importante del texto y que no haya sido destacada como palabra clave:

Add here a new word of the text: +

Ilustración 9-9: Campo para añadir una nueva palabra clave

En caso de querer añadirla, el sistema no comprobará que dicha palabra se encuentre en el texto, esa tarea se realizará más adelante:

Pacific
< 0 >

Peru
< 0 >

Rio
< 0 >

Valley
< 0 >

nuevaPalabra
< 0 >

Make Questions

Ilustración 9-10: Nueva palabra clave añadida al listado

Al seleccionar las palabras, el color de la caja que las contiene cambiará a verde para marcar que están seleccionadas, además de indicar con un número cuántas veces se han elegido, ya que ese número determinará la cantidad de preguntas que se generarán para dicha palabra en la siguiente fase:

Ohio
< 3 >

Old
< 0 >

Pacific
< 2 >

Peru
< 20 >

Rio
< 1 >

Tenochtitlán
< 0 >

Two-mile-thick
< 1 >

Valley
< 0 >

nuevaPalabra
< 1 >

e text:

+

Make Questions

Ilustración 9-11: Selección de varias palabras un número determinado de veces

Como se puede observar, la palabra ‘Peru’ ha sido seleccionada 20 veces, eso significa que el sistema, en la siguiente fase, va a intentar generar 20 preguntas distintas en las que salga la palabra Peru. En caso de no haber suficientes preguntas posibles, generará el máximo posible. Dicho caso es el de la palabra nueva añadida, al no aparecer en el texto, el sistema simplemente no genera una pregunta para la palabra clave.

9.2.5 Gestión de preguntas

Tras haber seleccionado las palabras clave que el usuario consideró oportunas, se generarán las preguntas en la ruta ‘/questions’:



Ilustración 9-12: Preguntas generadas por el sistema

Dichas preguntas aparecen en orden alfabético de la respuesta correcta.

Cada pregunta puede ser editada por el usuario, tanto enunciado como opciones:




Ilustración 9-13: Editando el enunciado de una pregunta




Ilustración 9-14: Editando las opciones de una pregunta

También pueden ser eliminadas:




Ilustración 9-15: Borrado de una pregunta

Además, en caso de que el usuario profesor quiera utilizar dicho examen generado para que sus alumnos repasen, puede guardar el examen con una id pública con la cual un estudiante podrá acceder al examen posteriormente:




Ilustración 9-16: Guardando examen en base de datos




Ilustración 9-17: Diálogo para insertar la id pública del examen a guardar en base de datos

También se le da la posibilidad al usuario profesor de descargar él mismo el examen en un documento de texto en formato Aiken:




Ilustración 9-18: Generación de link para descarga de examen



Ilustración 9-19: Link para descarga de examen

Al hacer clic en el enlace, se descargará el archivo:



Ilustración 9-20: Descarga del archivo de texto con el examen en formato Aiken

El contenido del fichero será el examen en formato Aiken:

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---




Ilustración 9-21: Fichero descargado con el examen en formato Aiken

9.2.6 Búsqueda de exámenes

Una vez un profesor haya creado un examen y lo haya guardado con una id pública, podrá hacerles llegar dicha id a sus estudiantes para que estos entren al mismo a realizarlo. La búsqueda del examen se realiza en la ruta '/exams':




Ilustración 9-22: Búsqueda de un examen por su id pública

El estudiante buscará con la id que utilizó el profesor al guardarlo:



Ilustración 9-23: Búsqueda de examen con id concreta, examenDePrueba

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO
			JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es

9.2.7 Realización de examen

Una vez el estudiante haya buscado el examen con la id que les hizo llegar el profesor, el sistema le mostrará el examen correspondiente en la ruta ‘/exam’:



This dramatic accident forever altered the future of both the Old World and the New, and of _____ and Asia as @link , Australia, Antarctica, and the Americas

- Africa
- Country
- California
- Mexico

Arab flesh merchants and _____ themselves had traded slaves for centuries before the Europeans arrived

- Appalachians

Ilustración 9-24: Vista de examen concreto con id examenDePrueba

El usuario estudiante podrá seleccionar en cada pregunta una opción:



This dramatic accident forever altered the future of both the Old World and the New, and of _____ and Asia as @link , Australia, Antarctica, and the Americas

- Africa
- Country
- **California**
- Mexico

Arab flesh merchants and _____ themselves had traded slaves for centuries before the Europeans arrived

- **Appalachians**
- Americans
- Africans
- Indians

Ilustración 9-25: Selección de opciones en la respuesta a un examen

Una vez haya terminado el examen, el usuario estudiante podrá comprobar los resultados y ver cuales ha acertado y cuales ha fallado:




Ilustración 9-26: Botón de corregir examen

Para cada pregunta, se mostrará el resultado en verde en caso de haber acertado:

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	---	---	--

This dramatic accident forever altered the future of both the Old World and the New, and of _____ and Asia as @link , Australia, Antarctica, and the Americas

- ☒ Africa
- ☐ Country
- ☐ California
- ☐ Mexico

CORRECT

Ilustración 9-27: Pregunta acertada

En rojo y con la respuesta correcta en caso de haber fallado:

Arab flesh merchants and _____ themselves had traded slaves for centuries before the Europeans arrived

- ☐ Appalachians
- ☐ Americans
- ☐ Africans
- ☒ Indians

WRONG, the correct answer was: Africans

Ilustración 9-28: Pregunta fallada

Y de igual manera a si hubiese sido fallada, si se dejó en blanco:

The majestic ranges of western North _____—the Rockies, the Sierra Nevada, the Cascades, and the Coast Ranges—arose much more recently, geologically speaking, some 135 million to 25 million years ago

- ☐ Age
- ☐ America
- ☐ Columbus
- ☐ Ice

WRONG, the correct answer was: America

Ilustración 9-29: Pregunta en blanco

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

10 Conclusiones y ampliaciones

Teniendo en consideración una vista general del proceso del proyecto y los resultados obtenidos, se podrían identificar nuevas metas u objetivos que hagan de este proyecto una evolución. A continuación, se exponen una serie de aspectos que están abiertos a ser mejorados y algunas propuestas de mejora.

10.1 Conclusiones

En cuanto al trabajo realizado durante estos meses, el proyecto llevado a cabo ha logrado profundizar en diversos conceptos de la extracción de palabras clave, el cual fue el principal objetivo al principio. Al ver los buenos resultados que otorgaban unos leves cambios en el algoritmo se optó por aplicar ese algoritmo que obtenía buenos resultados y centrarse en hacer una aplicación web que permitiese a los usuarios llevar a cabo diferentes funcionalidades, entre ellas, la principal de extracción de palabras clave y generación de preguntas de tipo test a partir de ellas.

De esa manera, el proyecto pasó a una fase de desarrollo web en la que se han conocido nuevos frameworks y librerías de gran uso y popularidad hoy en día, además de haber permitido llevar a cabo una web con un enfoque distinto a lo que se estaba acostumbrado, focalizado en otro tipo de usuarios.

A lo largo del proyecto se han ido documentando las fases importantes, planificación inicial, análisis, diseño, implementación... lo cual ha permitido obtener como resultado una documentación que sirve de gran utilidad a la hora de entender el proyecto, tanto para saber qué es lo que hace, cómo y por qué, como para saber utilizar la aplicación.

Al haber hecho la Restapi en un proyecto distinto a la Webapp, permite utilizar los servicios de extracción de palabras clave y generación de preguntas de manera independiente a la aplicación web, lo cual permite la reutilización de código. De la misma manera, la aplicación web ofrece una experiencia sencilla y fácil de entender, usable para que los usuarios se sientan cómodos en su interacción con la misma y no lleguen al bloqueo.

Finalmente, los objetivos del proyecto han sido cumplidos completamente al tener dos aplicaciones independientes que se comunican entre sí y ofrecen juntas una fácil y amplia generación de preguntas de tipo test para alimentar juegos online.

10.2 Líneas futuras

10.2.1 Líneas futuras relacionadas con la mejora del algoritmo

En esta sección se muestran los posibles puntos de mejora que podría tener el algoritmo y algunas propuestas para dichas mejoras.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

10.2.1.1 Mejora en los tiempos de ejecución

Si bien es cierto que los tiempos de ejecución del algoritmo no son altos (la media tras 5 ejecuciones fue cercana a 1 milisegundo de tiempo de ejecución), habrá maneras de optimizar el algoritmo, es una posible línea de mejora que queda abierta por si se quisiese perfeccionar más en este aspecto, sobre todo teniendo en cuenta que, al desplegar el servicio, los tiempos serán mayores.

10.2.1.2 Mejora en POS

En cuanto al uso que se hace de POS, como ya se comentó, el filtrado deja únicamente en la lista de posibles palabras clave a los sustantivos comunes y propios, tanto en singular como en plural. Aquí se abre una posible línea de mejora relacionada con ajustar cuáles podrían ser los mejores grupos gramaticales para realizar el procesado con POS.

Las pruebas iniciales realizadas lo que hacían era eliminar del texto las palabras que pertenecieran a determinadas categorías gramaticales, más adelante fue sustituido por, en vez de eliminar las que perteneciesen a unos determinados grupos, eliminar las que no formasen parte de unas pocas categorías (las de los sustantivos ya mencionados), en este punto es donde podría unirse a los sustantivos alguna otra categoría, como podrían ser los números, ya que, en los textos de historia suelen aparecer numerosas fechas.

A continuación, se muestran algunas categorías gramaticales que POS identifica y que podrían, en caso de realizarse una correcta combinación con los sustantivos, suponer una mejora en el algoritmo de extracción de palabras clave:

- CC: conjunción coordinada
- CD: numeral cardinal
- DT: determinante
- EX: pronombre existencial
- FW: palabra extranjera
- IN: preposición o subordinante
- JJ: adjetivo
- JJR: adjetivo comparativo
- JJS: adjetivo superlativo
- LS: marcador de lista
- MD: verbo modal
- NN: sustantivo singular o incontable
- NNS: sustantivo plural

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

- NNP: sustantivo propio singular
- NNPS: sustantivo propio plural
- PDT: determinante predeterminante
- POS: marcador posesivo
- PRP: pronombre personal
- PRP\$: pronombre posesivo
- RB: adverbio
- RBR: adverbio comparativo
- RBS: adverbio superlativo
- SYM: símbolo
- UH: interjección
- VB: verbo en infinitivo
- VBD: verbo en pasado simple
- VBG: verbo en gerundio
- VBN: verbo en participio pasado
- VBP: verbo en presente
- VBZ: verbo en presente, tercera persona del singular
- WDT: determinante interrogativo
- WP: pronombre interrogativo
- WP\$: pronombre posesivo interrogativo
- WRB: adverbio interrogativo

10.2.1.3 Aplicación de lógica borrosa o difusa

La lógica borrosa, también conocida como lógica difusa (del inglés Fuzzy Logic), es un enfoque en el campo de la inteligencia artificial y la teoría de conjuntos que se utiliza para lidiar con la incertidumbre y la imprecisión en la toma de decisiones y el razonamiento. A diferencia de la lógica tradicional, que se basa en valores binarios (verdadero o falso, 0 o 1), la lógica borrosa permite la representación y manipulación de valores que pueden estar en un estado intermedio o difuso entre verdadero y falso. En lugar de categorizar de manera rígida, la lógica borrosa permite la gradación de la verdad.

Algunas características clave de la lógica borrosa son las siguientes:

1. Valores Difusos: En la lógica borrosa, los valores pueden ser difusos, lo que significa que pueden estar en un continuo entre 0 y 1. Por ejemplo, en lugar de afirmar que algo es "verdadero" o "falso", se puede decir que tiene una cierta probabilidad de ser verdadero, como 0.7.
2. Conjuntos Difusos: En lugar de conjuntos nítidos y precisos, se utilizan conjuntos difusos, que permiten la inclusión gradual de elementos en un conjunto en función de su grado de pertenencia. Esto es especialmente útil cuando se trata de clasificar elementos en categorías que no son totalmente excluyentes.
3. Operaciones Borrosas: En la lógica borrosa, se utilizan operaciones difusas, como la conjunción y la disyunción borrosa, para combinar información de manera que sea coherente con la incertidumbre y la imprecisión.
4. Control Borroso: La lógica borrosa se utiliza en sistemas de control borroso, que son sistemas de control basados en reglas que manejan entradas y salidas difusas. Esto se aplica en campos como la automatización industrial y la robótica.
5. Aplicaciones: La lógica borrosa se utiliza en una amplia variedad de aplicaciones, como sistemas de recomendación, toma de decisiones en condiciones de incertidumbre, reconocimiento de patrones, procesamiento de señales, inteligencia artificial, robótica, y más.




Ilustración 10-1: Lógica borrosa aplicada gráficamente

La lógica borrosa es especialmente útil en situaciones en las que los datos no son absolutos y hay ambigüedad o imprecisión en la información. Permite una representación más realista y flexible de la toma de decisiones en entornos complejos. Su uso ha sido fundamental en campos donde la lógica clásica no puede manejar eficazmente la incertidumbre y la vaguedad. Es de esta manera que podría aplicarse a este trabajo en la búsqueda de palabras clave, ya que la respuesta a si una palabra es importante no siempre es si o no, en ocasiones es más ‘difuso’.

10.2.1.4 Codificador Universal de Oraciones (TensorFlow)

Un codificador universal de oraciones se refiere a un modelo de procesamiento de lenguaje natural que es capaz de tomar una oración o frase en lenguaje natural y convertirla en una representación numérica o vectorial que captura el significado y la semántica de la oración de manera general. Estos modelos se utilizan en tareas de

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	--

procesamiento de lenguaje natural, como traducción automática, resumen de texto, clasificación de texto y generación de lenguaje natural.

Un ejemplo destacado de un codificador universal de oraciones es BERT (Bidirectional Encoder Representations from Transformers). BERT es un modelo de lenguaje pre-entrenado desarrollado por Google que ha demostrado un rendimiento sobresaliente en una variedad de tareas de procesamiento de lenguaje natural. BERT utiliza una arquitectura basada en Transformers y ha sido entrenado en una gran cantidad de texto en línea para aprender las relaciones semánticas y sintácticas entre palabras y oraciones. A través del proceso de entrenamiento, BERT ha adquirido la capacidad de representar oraciones de manera efectiva en forma de vectores numéricos.

TensorFlow, por otro lado, es una biblioteca de código abierto desarrollada por Google para el aprendizaje automático y el procesamiento de datos. TensorFlow se ha convertido en una de las bibliotecas más populares y ampliamente utilizadas en el campo del aprendizaje automático y la inteligencia artificial. Permite la creación, entrenamiento y despliegue de modelos de aprendizaje automático, incluyendo modelos de procesamiento de lenguaje natural como BERT.

TensorFlow proporciona una amplia gama de herramientas y recursos para desarrolladores y científicos de datos, incluyendo:

- Una arquitectura de gráficos computacionales que permite definir y entrenar modelos de aprendizaje automático de manera eficiente.
- Una API flexible y escalable que permite la creación de modelos personalizados y la manipulación de datos.
- Herramientas para entrenar modelos en una variedad de plataformas, incluyendo CPU y GPU.
- Capacidades de despliegue para llevar modelos a producción en aplicaciones y servicios.
- Integración con TensorFlow Hub, un repositorio de modelos pre-entrenados que incluye modelos de procesamiento de lenguaje natural como BERT.




Ilustración 10-2: Ejemplo de cómo trabaja TensorFlow

Para aplicar esta herramienta a nuestro proyecto, se podría utilizar en el filtrado de palabras permitiendo eliminar del texto, además de los términos incluidos en las stopWords, otras palabras que tengan una relación semántica alta con cada una de ese listado.

Otro punto de vista podría ser añadir frases a la lista de stopWords y no solamente términos sueltos, de esta manera podríamos seguir eliminando frases que tengan significados parecidos y que carezcan de importancia en textos de esta temática.

10.2.2 Líneas futuras relacionadas con la mejora de la aplicación web y la obtención de preguntas

En esta sección se buscarán puntos de mejora en cuanto a la aplicación web y al algoritmo que permite obtener las preguntas a partir de las palabras clave.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO
			JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es

10.2.2.1 Subida de ficheros en otros formatos

La aplicación web permite solamente subida de ficheros de texto (.txt), además de permitir pegar el contenido del documento en un área de texto. Como mejora futura podría permitir la subida de archivos de otros formatos como podría ser PDF o Word, lo que aumentaría las posibilidades de la aplicación.

10.2.2.2 Agrupamiento de keywords alfabéticamente

En cuanto a la pantalla de la aplicación web en la que se muestran las keywords para que el usuario seleccione las palabras a partir de las cuales generar las preguntas de tipo test, dichas palabras ya están ordenadas alfabéticamente para facilitar al usuario buscar algún término en concreto, sin embargo, en los casos en los que los resultados ofrezcan demasiados valores (como se vio anteriormente, para determinados documentos, el número de FP ascendían a números cercanos a 150) podría ser adecuado insertar un sistema de clasificación o paginación, de manera que haya un índice por letra y en cada letra estén agrupadas las palabras que comiencen por la misma. Es muy probable que así sea más fácil ubicarse y encontrar los términos que se están buscando, así como comprobar si ya hay uno de ellos y se desea añadir a mano en caso de no encontrarse entre los resultados del algoritmo.

10.2.2.3 Añadir nuevos tipos de preguntas

El sistema únicamente genera preguntas de tipo test en las que se debe rellenar un hueco en blanco con una de las palabras que se dan como opciones, esta es una de muchas maneras de hacer preguntas. Otras posibles preguntas a generar son:

- **Preguntas de desarrollo:** habría que modelar el enunciado a modo de pregunta y la respuesta sería un texto escrito por el estudiante en lugar de solamente seleccionar una opción.
- **Preguntas de emparejamiento:** permitirían asociar conceptos uniéndolos.
- **Preguntas de verdadero o falso:** se debe juzgar si el enunciado es verdadero o falso, siendo estas dos las únicas opciones de respuesta.
- **Preguntas de tipo test puras:** al igual que en las de desarrollo habría que modelar el enunciado a modo de pregunta y las respuestas serían como en el proyecto realizado, de manera que el estudiante mediante una opción, diese respuesta al enunciado.
- **Preguntas de tipo test de opción múltiple:** preguntas de tipo test puras pero cuya respuesta correcta está formada por más de una opción.

10.2.2.4 Utilización de alguna librería de componentes

La aplicación tiene un diseño propio, con aplicación de estilos mediante CSS a mano. Sería interesante introducir una librería de componentes, algunas de las más usadas con React son:

- **Ant Design:** es una biblioteca de componentes React con un enfoque en la eficiencia y la consistencia visual. Proviene del ecosistema de diseño de Ant Design, utilizado por Alibaba, y ofrece un conjunto completo de componentes para el desarrollo de aplicaciones empresariales.
 - **Ventajas:** diseño consistente y profesional, además de comunidad activa y amplia documentación.
 - **Inconvenientes:** curva de aprendizaje puede ser empinada debido a la cantidad de opciones que ofrece. Además, puede impactar negativamente en el tamaño de la aplicación si no se gestiona adecuadamente.
- **Material-UI:** biblioteca de componentes de React que implementa el diseño y las directrices de Material Design de Google. Proporciona una amplia variedad de componentes preestilizados y temas que siguen los principios de Material Design, lo que facilita la creación de interfaces de usuario atractivas y coherentes.
 - **Ventajas:** integración sencilla con React y una amplia y exhaustiva comunidad activa.
 - **Inconvenientes:** puede tener un tamaño de bundle excesivo si no se gestiona adecuadamente y la personalización avanzada puede requerir bastante tiempo de aprendizaje.
- **Bootstrap:** es un popular framework de diseño web que ofrece un conjunto de componentes y estilos predefinidos. React-Bootstrap es la versión adaptada de Bootstrap para React, que permite utilizar los componentes de Bootstrap de manera más eficiente en aplicaciones React.
 - **Ventajas:** compatible con diferentes frameworks CSS, no solo Bootstrap y ampliamente usado y probado en la industria.
 - **Inconvenientes:** los estilos predeterminados pueden no alinearse perfectamente con las guías de diseño específicas de React y puede requerir estilos adicionales o personalización extra para adecuarse al diseño deseado.

Cabe destacar que en el proyecto desarrollado se utilizó Ant Design, pero únicamente en las fases finales como ayuda para dar solución a algunos problemas. Si se utilizase en mayor profundidad, la aplicación podría obtener un diseño más adecuado a la experiencia del usuario.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO
			JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es

10.2.2.5 Aplicar un sistema de seguridad a la web

10.2.2.5.1 Rutas

En la aplicación no se han llevado a cabo requisitos de seguridad de acceso a rutas, es por ello que, si se intenta acceder sin estar identificado, el sistema lo permitirá. Esto es debido a que no era el enfoque principal del proyecto y se ha focalizado el esfuerzo en el desarrollo de los algoritmos del backend y la interfaz de la web.

10.2.2.5.2 Contraseñas

De igual manera que en el apartado anterior, no se focalizaron los esfuerzos en la seguridad de contraseñas, es por ello que las contraseñas no se encriptan para guardarlas en la base de datos.

10.2.2.5.3 Validaciones de formularios

Al igual que en los apartados anteriores, las validaciones de los formularios de la aplicación no fueron el objetivo principal de los esfuerzos, es por ello que en ocasiones no existen dichas validaciones como puede ser una longitud mínima en una contraseña o un formato correcto a un email.

10.2.2.6 Exportación de las preguntas a otros formatos

En la aplicación web, en el mismo momento que en el apartado anterior, si se elige la opción de exportar las preguntas, solamente deja en un formato, dicho medio es el formato Aiken, el cual permite la creación de cuestionarios con múltiples opciones.

Sería una buena opción permitir que los usuarios pudieran exportar las preguntas a otros formatos como PDF o Word.

11 Referencias bibliográficas

- [1] Tf-idf. (2019, diciembre 11). En Wikipedia. Recuperado de <https://es.wikipedia.org/wiki/Tf-idf>
- [2] “YAKE: un extractor de palabras clave potenciado por IA”. (2022, Enero 12). En Wwhatsnew. Recuperado de <https://wwwwhatsnew.com/2022/01/12/yake-un-extractor-de-palabras-clave-potenciado-por-ia/>
- [3] F-Score. (2023, abril 4). En Wikipedia. Recuperado de <https://en.wikipedia.org/wiki/F-score>
- [4] Precisión y exhaustividad. (2022, mayo 2). En Wikipedia. Recuperado de https://es.wikipedia.org/wiki/Precisi%C3%B3n_y_exhaustividad
- [5] Sensibilidad y especificidad. (2022, agosto 16). En Wikipedia. Recuperado de https://es.wikipedia.org/wiki/Sensibilidad_y_especificidad
- [6] “Deploying a Render”. (s.f.). En Astro Docs. Recuperado de <https://docs.astro.build/es/guides/deploy/render/>
- [7] Juan Espínola. (2023, enero 27). En Juanse.dev Blog. Recuperado de <https://juanse.dev/blog/deploy-api-render>
- [8] “Hosting on Render”. (2023, mayo 15). En gohugo.io. Recuperado de <https://gohugo.io/hosting-and-deployment/hosting-on-render/>
- [9] “Para qué sirve React JS: beneficios para tus apps”. (2021, octubre 4). En Doonamis. Recuperado de <https://www.doonamis.es/para-que-sirve-react-js-beneficios-para-tus-apps/>
- [10] “Acerca de GitHub Pages”. (2023). En GitHub. Recuperado de <https://docs.github.com/es/pages/getting-started-with-github-pages/about-github-pages>
- [11] D. M. Gamo, M. C. S. F. Baonza (s.f.). Del estudio “Razonamiento con imprecisión: Lógica Borrosa”. Recuperado de <https://oa.upm.es/46795/1/LogicaBorrosa.pdf>
- [12] “Codificador de oración universal”. (2022, enero 6). En Tensorflow. Recuperado de

https://www.tensorflow.org/hub/tutorials/semantic_similarity_with_tf_hub_universal_encoder?hl=es-419

- [13] Google. (s.f.). En tfhub.dev. Recuperado de <https://tfhub.dev/google/universal-sentence-encoder/4>
- [14] “Formato Aiken”. (2022, marzo 17). En Moodle. Recuperado de https://docs.moodle.org/all/es/Formato_Aiken
- [15] Q. Liu, J. Wang, D. Zhang, Y. Yang, N. Y. Wang. (2018). Text Features Extraction based on TF-IDF Associating Semantic. International Conference on Computer and Communications, 4th, 6.
- [16] L. Yao, Z. Pengzhou, Z. Chi. (2019, junio 19). Research on News Keyword Extraction Technology Based on TF-IDF and TextRank. School of Computer Science of China, 4.
- [17] C. Liu, Y. Sheng, Z. Wei, Y. Q. Yang. (2018). Research of Text Classification Based on Improved TF-IDF Algorithm. International Conference of Intelligent Robotic and Control Engineering, 5.
- [18] S. JABRI, A. DAHBI, T. GADI, A. BASSIR. (s.f.). Ranking of Text Documents using TF-IDF Weighting and Association Rules mining, 6.
- [19] X. Huang, Q. Wu. (s.f.). Micro-blog Commercial Word Extraction Based On Improved TF-IDF Algorithm, 5.
- [20] P. Bafna, D. Pramod, A. Vaidya. (2016). Document Clustering: TF-IDF approach. International Conference on Electrical, Electronics, and Optimization Techniques (ICEEOT), 6.
- [21] N. Wang, P. Wang, B. Zhang. (2010). An Improved TF-IDF Weights Function Based on Information Theory. International Conference on Computer and Communication Technologies in Agriculture Engineering, 3.
- [22] L. H. Patil, M. Atique. (2013). A Novel Approach for Feature Selection Method TF-IDF in Document Clustering. IEEE International Advance Computing Conference (IACC), 3rd, 5.

12 Glosario

Frontend	<i>El Frontend se refiere a la capa de un sistema de software o sitio web que se encarga de la presentación y la interacción directa con el usuario final. Incluye todos los elementos visuales y funcionales que los usuarios ven y utilizan en la pantalla, como el diseño de la interfaz de usuario, las páginas web, los formularios, los botones, los menús, las imágenes y otros componentes. El Frontend se crea mediante el uso de tecnologías como HTML (HyperText Markup Language) para la estructura del contenido, CSS (Cascading Style Sheets) para la presentación y el diseño visual, y JavaScript para la interactividad y la funcionalidad en tiempo real.</i>
Backend	<i>El Backend se refiere a la parte del sistema de software o sitio web que se encuentra detrás de escena y que no es visible para los usuarios finales. Esta capa se encarga de gestionar los aspectos técnicos y funcionales del sistema, como el procesamiento de datos, la lógica empresarial, el almacenamiento de información en bases de datos y la comunicación con otros sistemas. El backend se compone de servidores, aplicaciones y bases de datos que trabajan en conjunto para brindar funcionalidad a la aplicación o sitio web.</i>
Caso de uso	<i>Un caso de uso es una descripción detallada de cómo un sistema de software interactúa con sus usuarios o con otros sistemas, mostrando cómo se utilizan las funcionalidades del sistema en situaciones específicas. Los casos de uso son una técnica de modelado en el desarrollo de software que se utiliza para capturar, definir y comprender los requisitos y comportamientos del sistema desde la perspectiva de los usuarios o actores involucrados.</i>
Escenario	<i>Un "escenario" en el contexto de la ingeniería de software, y específicamente en la documentación de casos de uso, se refiere a una descripción detallada de una serie de pasos o eventos que ilustran cómo un caso de uso específico se desarrolla en una situación dada. Los escenarios se utilizan para proporcionar una narrativa coherente y comprensible de cómo los usuarios o actores interactúan con el sistema en el contexto de un caso de uso particular.</i>
Framework	<i>Un framework en el contexto del desarrollo de software se refiere a una estructura predefinida y una colección de</i>

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	--

	<i>herramientas, bibliotecas y estándares que simplifican y agilizan el proceso de desarrollo de aplicaciones. Los frameworks proporcionan una base sólida sobre la cual los desarrolladores pueden construir aplicaciones, permitiendo una mayor eficiencia y reutilización de código.</i>
JSON	<i>JSON es un formato de intercambio de datos ligero y fácilmente legible por humanos que se utiliza en el intercambio de información entre sistemas informáticos. Es una representación de datos estructurados que sigue una sintaxis sencilla y es ampliamente utilizado en el desarrollo de aplicaciones web y servicios web.</i>
Requisito	<i>Un requisito en el contexto de desarrollo de software se refiere a una declaración o especificación que describe una necesidad, restricción o característica que debe ser satisfecha por un sistema de software o una aplicación. Los requisitos son una parte esencial del proceso de desarrollo de software y sirven como la base para el diseño, la implementación y las pruebas de un sistema.</i>

13 Anexos

13.1 Plan de gestión de riesgos

El plan de gestión de riesgos es un componente crucial dentro de la gestión de proyectos informáticos. El objetivo principal es identificar, analizar y planificar cómo se manejarán los riesgos a lo largo del ciclo de vida del proyecto. Para llevarlo a cabo se ha decidido seguir los siguientes procesos:




Ilustración 13-1: Plan de gestión de riesgos

A continuación, se comenta en qué consistiría cada fase:

- **Planificar la gestión de riesgos:** en esta fase se decidirá acerca de qué políticas tomar en cuanto a la gestión de riesgos.
- **Valorar los riesgos:** en esta fase se procederá a la identificación, análisis y priorización de riesgos. Estos procesos se realizan al inicio del proyecto, aunque tienen carácter iterativo, es decir, pueden realizarse más iteraciones en caso de ser necesario ajustarlos.
- **Gestionar los riesgos:** en esta fase final, se trata de planificar la gestión de cada riesgo, resolución y monitorización de los riesgos. Estos procesos son iniciados al comienzo del proyecto, pero tendrán durante el desarrollo del mismo una gran importancia.

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es
---	--	---	---

13.1.1 Valoración de riesgos

13.1.1.1 Identificar riesgos

El objetivo de esta fase es recopilar los posibles riesgos que pueden afectar al proyecto. Para ello se aplicarán las siguientes técnicas:

- **Lluvia de ideas:** en primer lugar, una primera impresión de la visión de los riesgos proporcionando ideas libremente.
- **Entrevistas:** en caso de considerar escasa una primera iteración con lluvia de ideas, se procederá a realizar entrevistas estructuradas, en este caso al tutor (el cual se puede considerar como cliente), para la obtención de posibles riesgos.
- **Análisis de documentación:** en último lugar, analizar la documentación en busca de posibles fisuras o partes del proyecto que puedan ser más vulnerables.

Tras esta fase de identificación, se obtendrá un conjunto de riesgos. Cada uno de ellos tendrá una información mínima, la cual será: identificador, categoría, nombre y descripción.

13.1.1.2 Analizar riesgos

Tras la identificación inicial de riesgos, se procede en esta fase al análisis de los mismos, el cual dará como resultado para cada uno de los riesgos un valor de impacto. Dicho valor estará comprendido entre 0 y 1, representando cómo de crítico es cada riesgo.

Además, a cada riesgo se le asignará una probabilidad, la cual representa cómo de probable es que se dé el suceso que se contempla en el riesgo.

De esta manera, cada riesgo saldrá del análisis con la siguiente información:

- Identificador
- Categoría
- Nombre
- Descripción
- Impacto
- Probabilidad

13.1.1.3 Priorizar riesgos

En la última fase de la valoración de los riesgos, se procederá a priorizarlos, basándose en su impacto y probabilidad. El objetivo es que se pueda enfocar una gestión de riesgos (siguiente fase a la valoración de estos) comenzando por los más prioritarios.

13.1.2 Gestión de riesgos

13.1.2.1 Planificar la gestión de cada riesgo

Una vez se tiene un conjunto de riesgos priorizados obtenido de la valoración, se procederá en esta fase a determinar la estrategia a seguir para cada riesgo. A continuación, se muestran las estrategias contempladas para cada riesgo:

- **Eliminar riesgo:** esta estrategia consiste en extinguir los factores que podrían hacer que el riesgo se produjese.
- **Transferir riesgo:** mediante esta técnica se consigue delegar la responsabilidad de gestionar o responder al riesgo a un tercero mediante la contratación de algún servicio externo.
- **Mitigar riesgo:** la mitigación consiste en tener identificados y controlados los factores que pueden hacer que se produzca el riesgo, teniendo controlado el impacto lo máximo posible.
- **Asumir riesgo:** esta última estrategia consiste en aceptar el riesgo conscientemente y estar preparado por si se materializa. Puede ser necesaria en casos en los que sea inviable por motivos de coste o complejidad aplicar otra técnica.

Tras esta fase, se obtiene el conjunto de riesgos, cada uno de ellos con la información acumulada de los anteriores procesos, además de la estrategia a aplicar en cada caso con una justificación de la decisión tomada.

13.1.2.2 Resolución de riesgos

En esta fase se comprobaría que se han aplicado las estrategias tomadas en el apartado anterior y en caso de no ser así se buscaría aplicarla. Dicho esto, esta es una fase que no se llevará a cabo en el proyecto.

13.1.2.3 Monitorizar riesgos

En este punto se trataría de, tras haber identificado y dado solución a los riesgos identificados (dentro de lo posible y las estrategias tomadas), dar un seguimiento a los riesgos a medida que avanza el proyecto. Esta fase es otra que no se pondrá en práctica en el trabajo a realizar.

13.2 Contenido de los anexos entregados

Ha sido entregado un archivo nombrado ‘Anexos.zip’, el cual contiene lo siguiente:

- **URLs:**

	ESCUELA DE INGENIERÍA INFORMÁTICA		ALGORITMO PARA LA EXTRACCIÓN DE PALABRAS CLAVE EN TEXTOS EDUCATIVOS TRABAJO FIN DE GRADO
			JORGE LÓPEZ PELÁEZ – uo276514@uniovi.es

- **A directorio Histkey_TFG:** la cual enlaza con un directorio en el que se encuentran las carpetas de las dos partes del proyecto, la Webapp y la Restapi, conteniendo cada uno su código correspondiente.
- **Al repositorio de la Webapp:** donde se encuentra también todo el código correspondiente al Frontend de la aplicación.
- **Al repositorio de la Restapi:** donde se encuentra también todo el código correspondiente al Backend de la aplicación.